Recurrent Neural Network (RNN)

汇报人：扣扣

大纲

- 循环神经网络应用

- 简单版本RNN
- 简单版本RNN存在问题

- LSTM基本结构解析
- GRU基本结构解析
- LSTM代码示例
- 相关面试题
- 作业

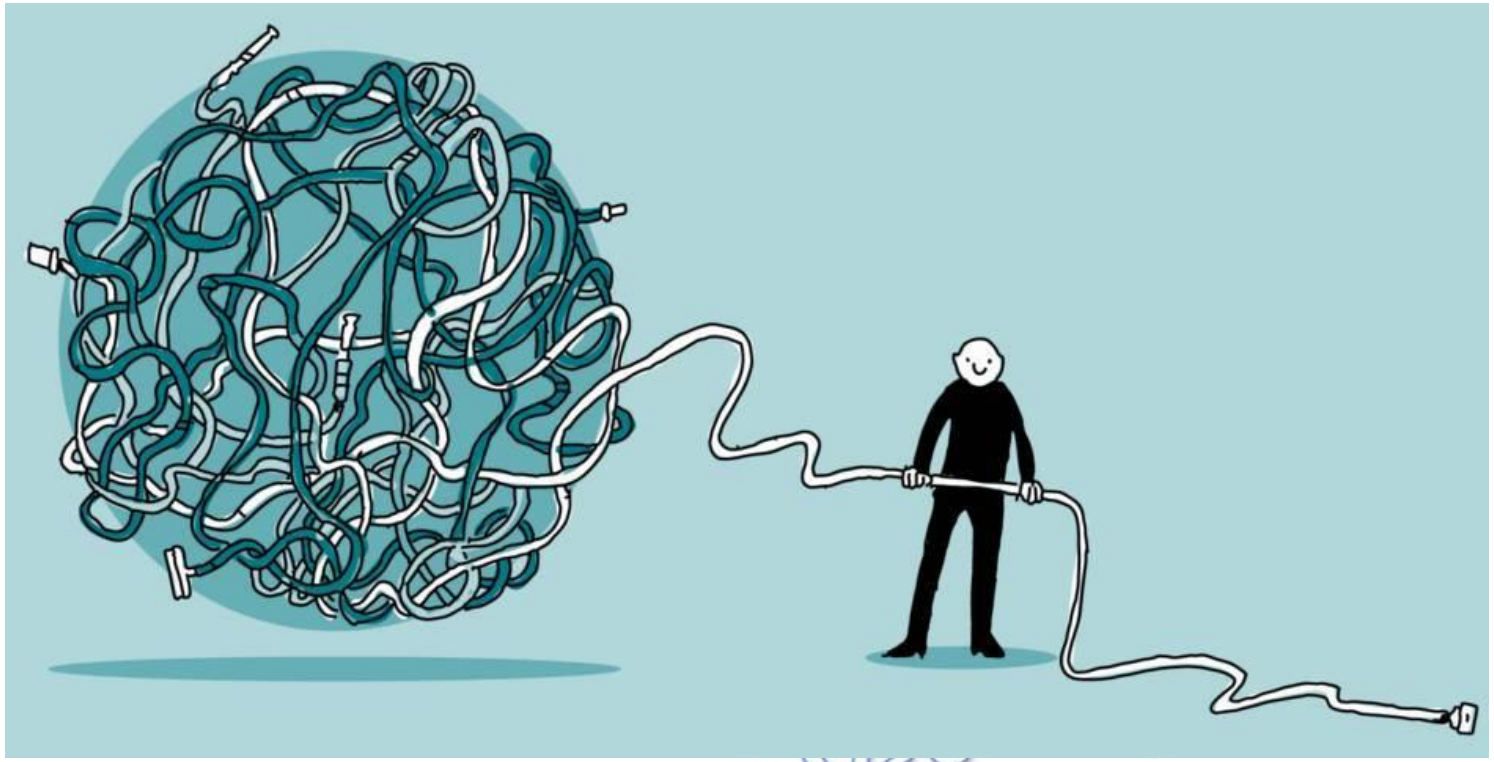

应用：情感分类

这家店的装修不错。

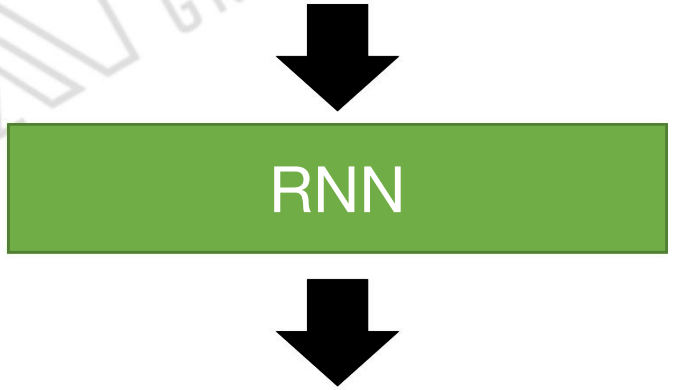

正面

这家店的装修不错，但牛排是过期的。

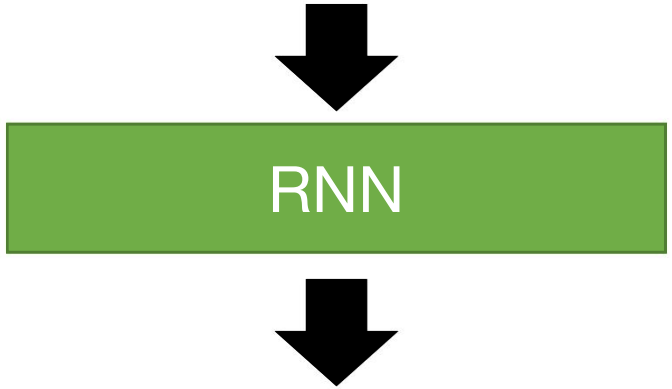

负面

记忆能力

应用：chatbot

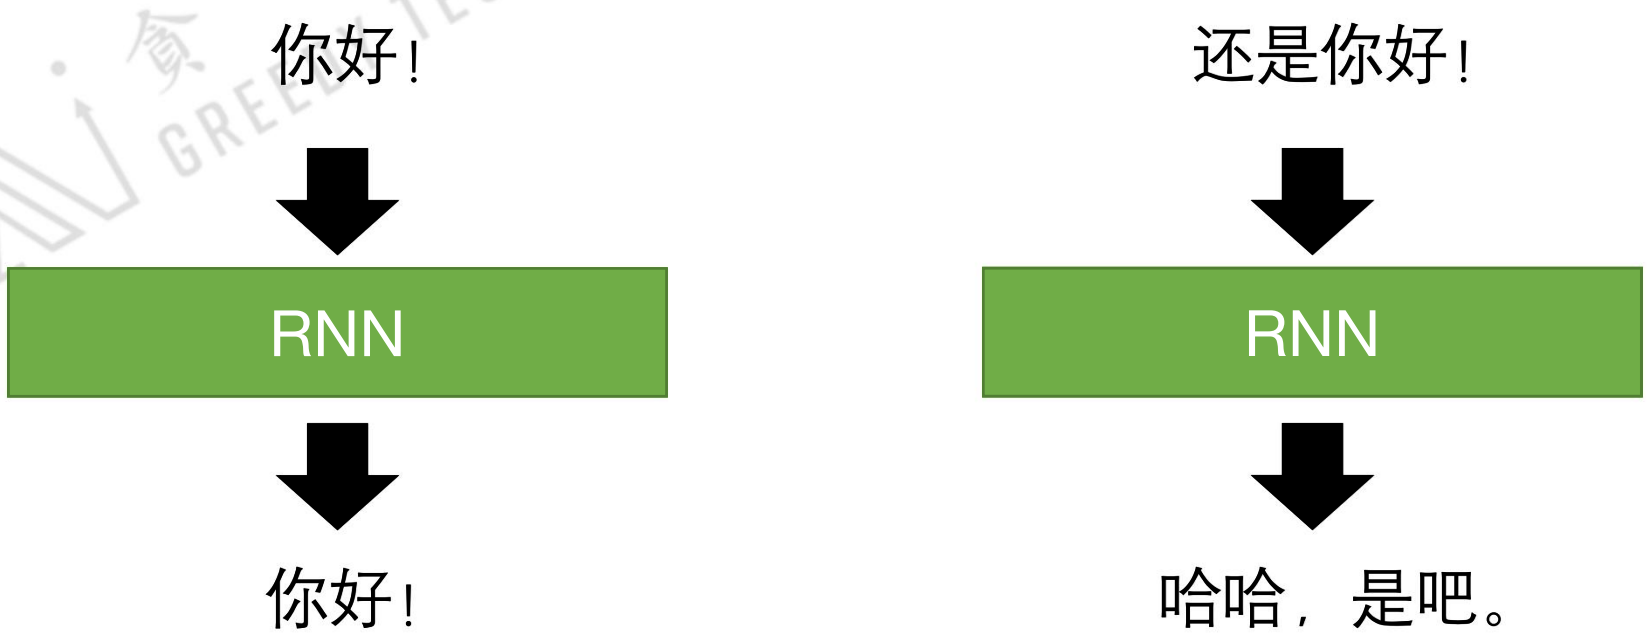

记忆能力

应用：诗词生成

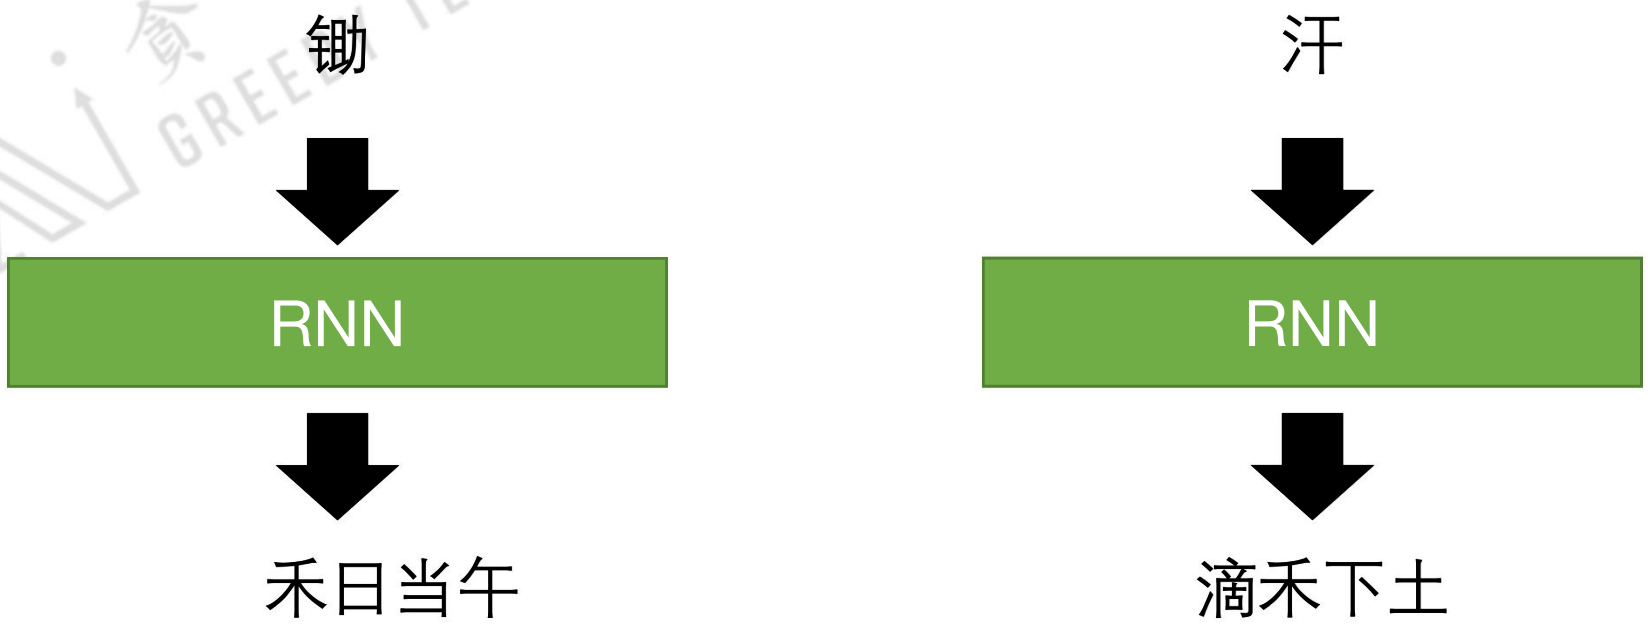

记忆能力

应用：流畅性评价

今天是周六

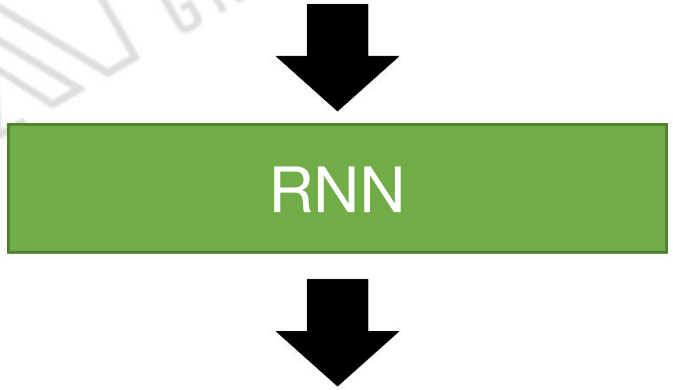

ppl: 100

是今天周六

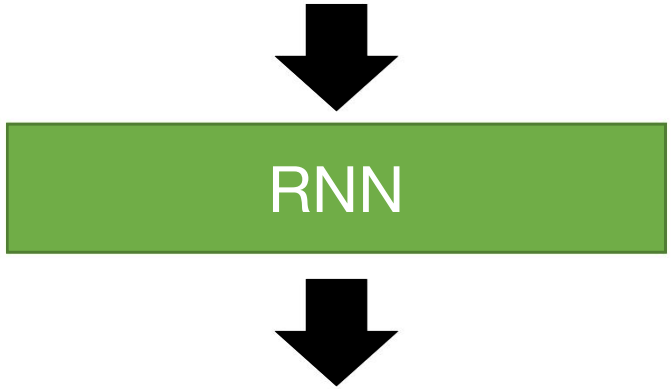

ppl: 1000

$$perplexity(S) = p(w_1, w_2, w_3, \ldots, w_m)^{-1/m} \quad (1)$$
$$= \sqrt[m]{\prod_{i=1}^{m} \frac{1}{p(w_i|w_1, w_2, \ldots, w_{i-1})}}$$

记忆能力

应用：填槽（slot）填充

京东智联云 &

记忆能力

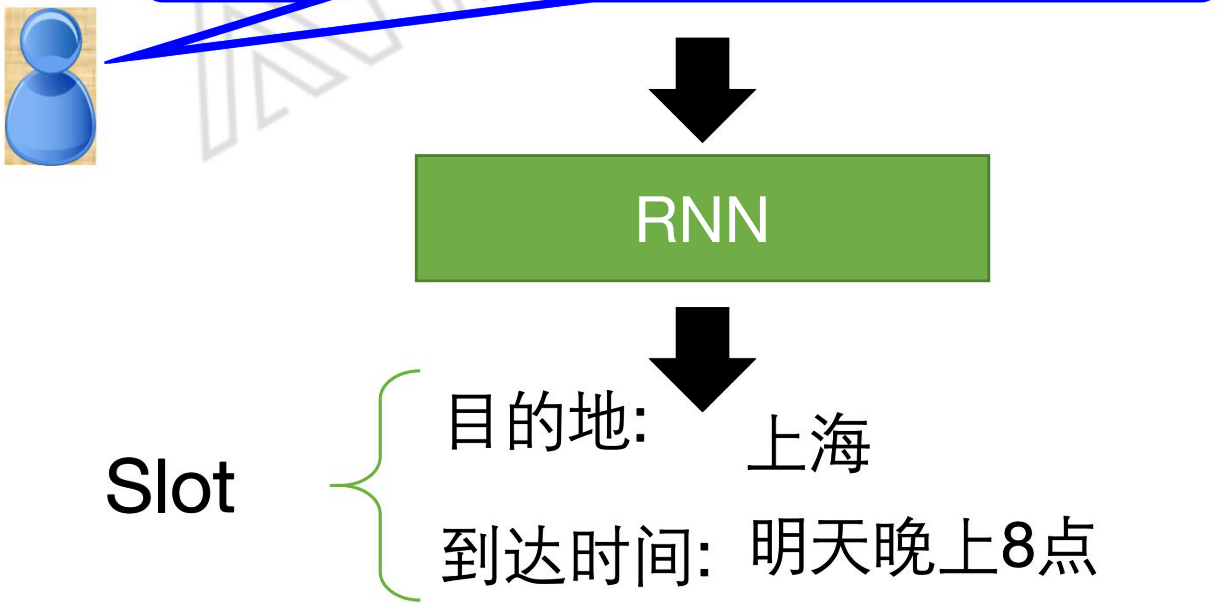

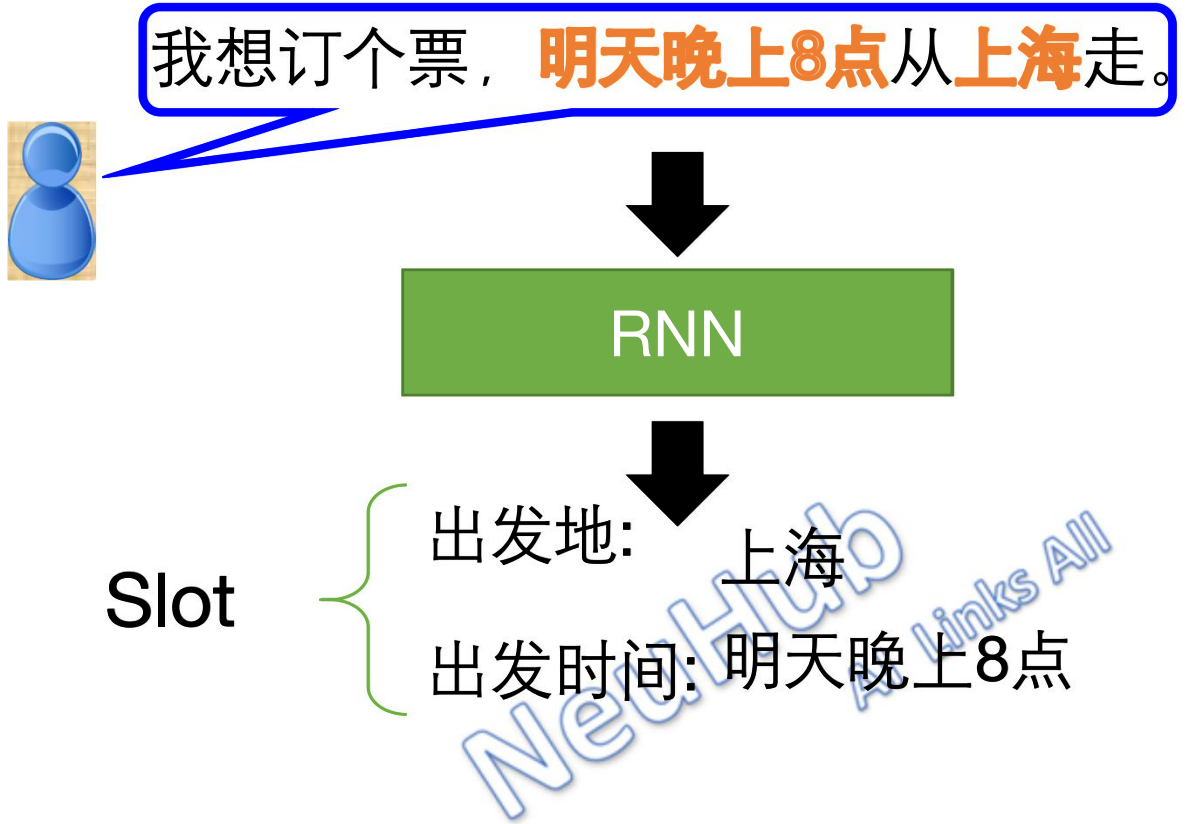

为什么需要RNN

某些任务需要能够更好地处理序列信息，
即前面的输入和后面的输入是有关系的，
因此需要模型具备记忆能力。

RNN

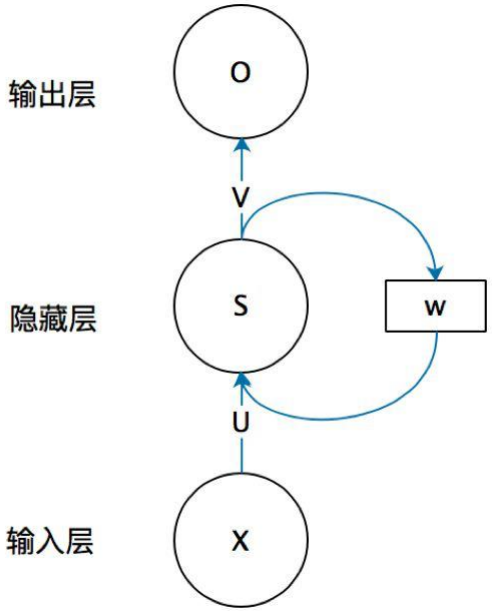

x是一个向量，它表示某个时刻输入层的值（多个时刻的x组成一个序列）；s是一个向量，它表示隐藏层的值；

U是输入层到隐藏层的权重矩阵，o也是一个向量，它表示输出层的值；V是隐藏层到输出层的权重矩阵。

W是什么：循环神经网络的隐藏层的值s不仅仅取决于当前这次的输入x，还取决于上一次隐藏层的值s。权重矩阵 W就是隐藏层上一次的值作为这一次的输入的权重。

RNN

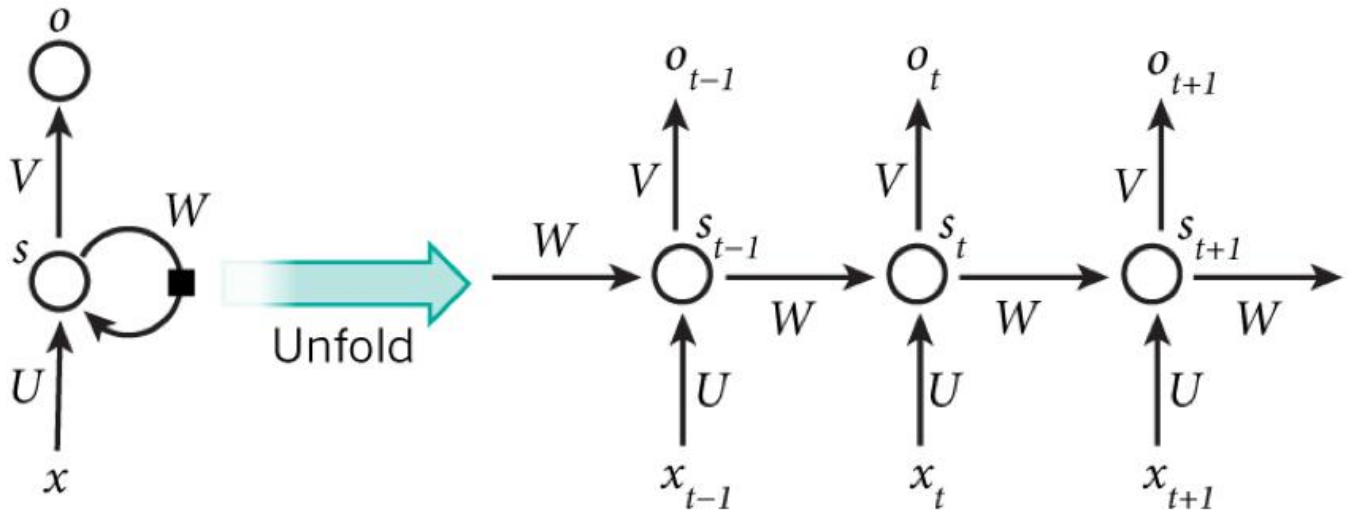

$$o_t = g(Vs_t) \quad (式1)$$

$$s_t = f(Ux_t + Ws_{t-1}) \quad (式2)$$

第一个式子是输出层的计算公式，输出层是一个全连接层，也就是它的每个节点都和隐藏层的每个节点相连。V是输出层的权重矩阵，g是激活函数。

第二个式子是隐藏层的计算公式，它是循环层。U是输入x的权重矩阵，W是上一次的s的权重矩阵，f是激活函数。

从上面的公式我们可以看出，循环层和全连接层的区别就是循环层多了一个权重矩阵 W。

注意：W，V，U为共享权重。

RNN

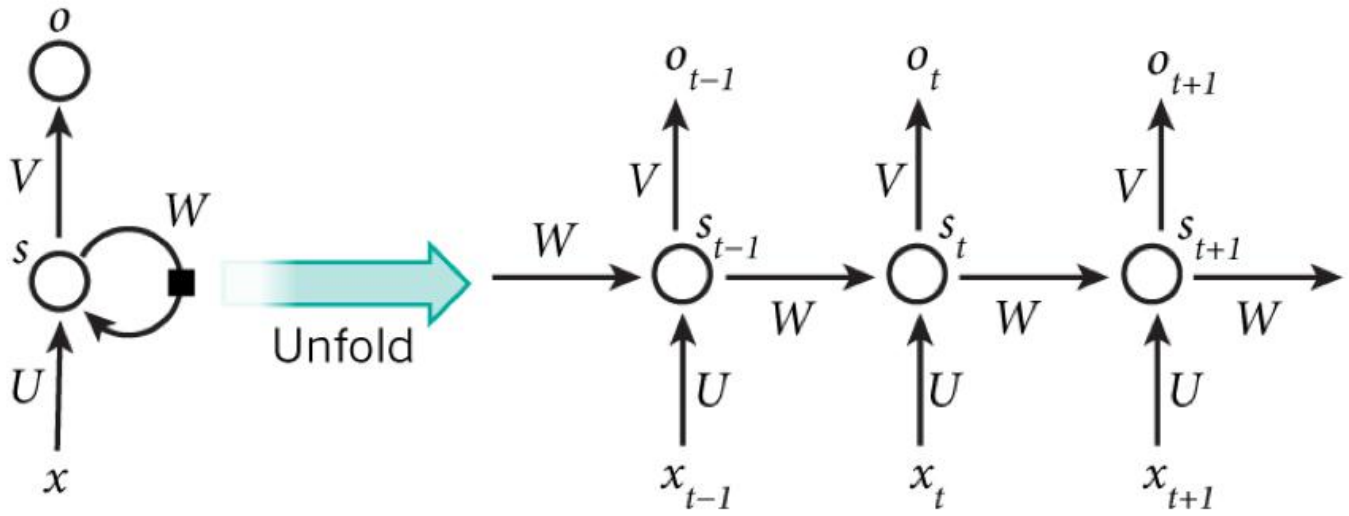

$$o_t = g(Vs_t) \quad (式1)$$

$$s_t = f(Ux_t + Ws_{t-1}) \quad (式2)$$

思考：

- W，V，U有多少个？
- 假如x为4维向量，s为3维向量，U,W的大小分别为多少？

RNN

$$o_t = g(Vs_t) \quad (式1)$$
$$s_t = f(Ux_t + Ws_{t-1}) \quad (式2)$$

思考：

- W，V，U有多少个？
- 假如x为m维向量，s为n维向量，U,W的大小分别为多少？

$$\begin{bmatrix} s_1^t \\ s_2^t \\ . \\ . \\ s_n^t \end{bmatrix} = f(\begin{bmatrix} u_{11} u_{12} \dots u_{1m} \\ u_{21} u_{22} \dots u_{2m} \\ . \\ . \\ u_{n1} u_{n2} \dots u_{nm} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ . \\ . \\ x_m \end{bmatrix} + \begin{bmatrix} w_{11} w_{12} \dots w_{1n} \\ w_{21} w_{22} \dots w_{2n} \\ . \\ . \\ w_{n1} w_{n2} \dots w_{nn} \end{bmatrix} \begin{bmatrix} s_1^{t-1} \\ s_2^{t-1} \\ . \\ . \\ s_n^{t-1} \end{bmatrix})$$

RNN

$$o_t = g(Vs_t) \quad (式1)$$
$$s_t = f(Ux_t + Ws_{t-1}) \quad (式2)$$

$$\begin{aligned} o_t &= g(Vs_t) \\ &= Vf(Ux_t + Ws_{t-1}) \\ &= Vf(Ux_t + Wf(Ux_{t-1} + Ws_{t-2})) \\ &= Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Ws_{t-3}))) \\ &= Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Wf(Ux_{t-3} + \dots)))) \end{aligned}$$

总结：可以看出，循环神经网络的输出值，受前面历次输入值x1、x2...xt-1影响，这就是为什么循环神经网络具备记忆能力的原因。

RNN

- 很多现实中的数据都是序列数据，前后相关，需要具备记忆能力的模型来建模。
- 比如，当我们在理解一句话意思时，孤立的理解这句话的每个词是不够的，我们需要处理这些词连接起来的整个序列；当我们处理视频的时候，我们也不能只单独的去分析每一帧，而要分析这些帧连接起来的整个序列。

双向RNN

完形填空

Jim was a worker. One of his feet was bigger than __1__. He couldn't __2____ the right shoes __3__ his feet. One day his friend Mike said to him "__4__ don't you go to a shoemaker? A good shoemaker can ____5__ you the right shoes." __6____ Jim went to the shoemaker near Mike's home, very soon the shoemaker finished the work. Jim__7__ the shoes and wasn't happy. He __8__ the shoemaker "You aren't a __9____ shoemaker! I wanted you to make me one shoe bigger than the other, __10__ you made me one shoe smaller than the other."

( )1. A. other B. the other C. another D. that one
( )2. A. see B. look for C. find D. find out
( )3. A. for B. with C. on D. of
( )4. A. When B. Where C. How D. Why
( )5. A. make B. pass C. do D. give
( )6. A. Then B. But C. So D. Because
( )7. A. saw B. watched C. found D. looked at
( )8. A. said B. said to C. spoke D. talked
( )9. A. good B. bad C. right D. kind
( )10. A. then B. and C. but D. so

阅读理解

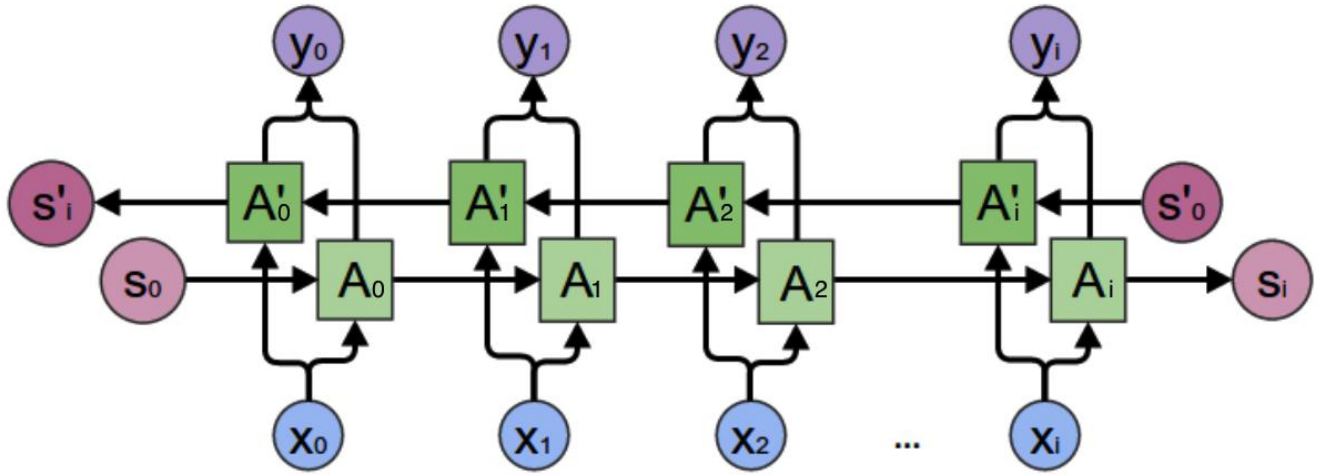

简单版本的循环神经网络无法对此进行建模，因此，我们需要双向循环神经网络。

双向RNN

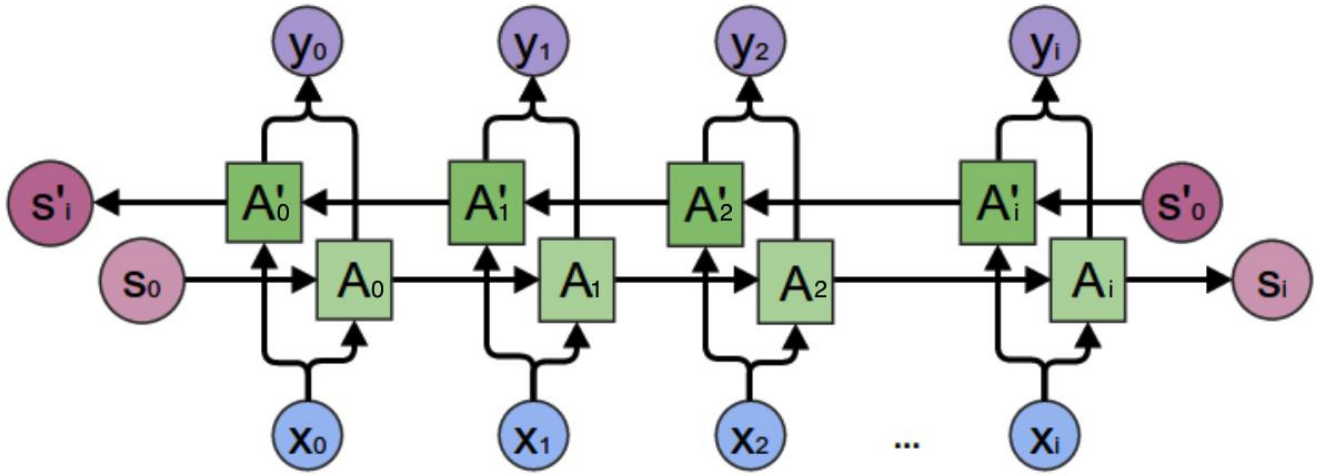

$$y_2 = g(VA_2 + V'A'_2)$$

$$A_2 = f(WA_1 + Ux_2)$$
$$A'_2 = f(W'A'_3 + U'x_2)$$

从上图可看出，双向循环神经网络的隐藏层要保存两个值，一个A参与正向计算，另一个值A'参与反向计算。如，最终y2的输出值取决于A2和A2'。

规律：正向计算时，隐藏层的值At与At-1有关；反向计算时，隐藏层的值At'与At+1'有关；最终的输出取决于正向和反向计算的加和。

双向RNN

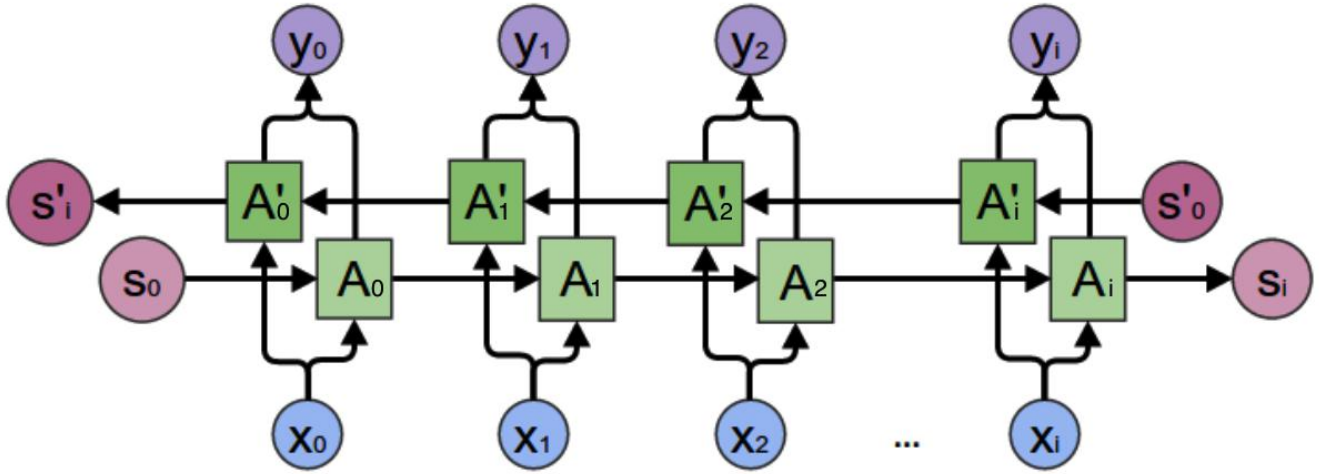

$$y_2 = g(VA_2 + V'A'_2)$$

$$A_2 = f(WA_1 + Ux_2)$$
$$A'_2 = f(W'A'_3 + U'x_2)$$

$$o_t = g(Vs_t + V's'_t)$$

正向计算和反向计算不共享权重，也就是说U和U'、W和W'、V和V'都是不同的权重矩阵。

深度RNN

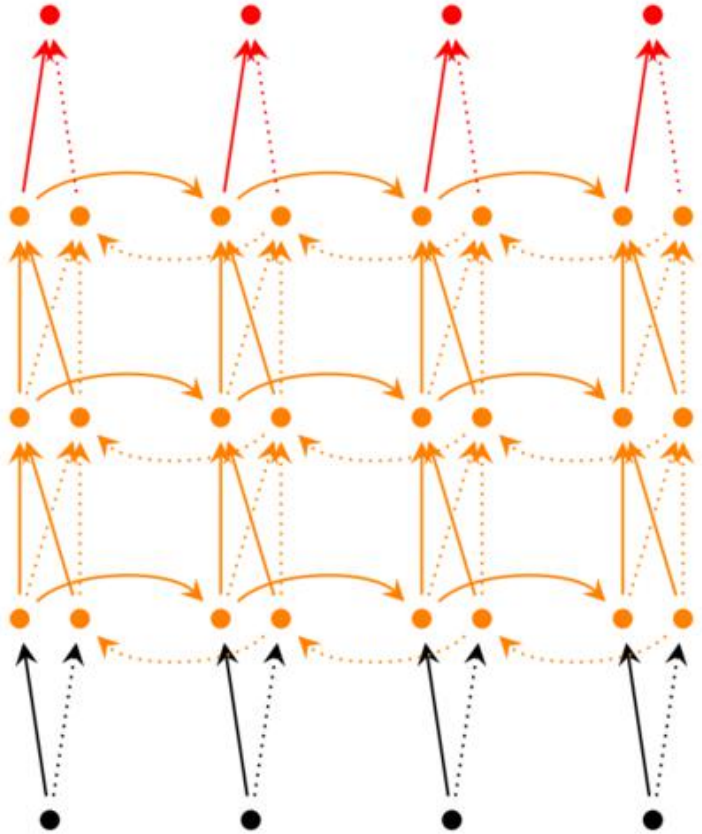

前面介绍的循环神经网络只有一个隐藏层，当然也可以根据任务及数据情况，堆叠两个以上的隐藏层，这样就得到了深度循环神经网络。

RNN与梯度消失、梯度爆炸

- RNN很难训练

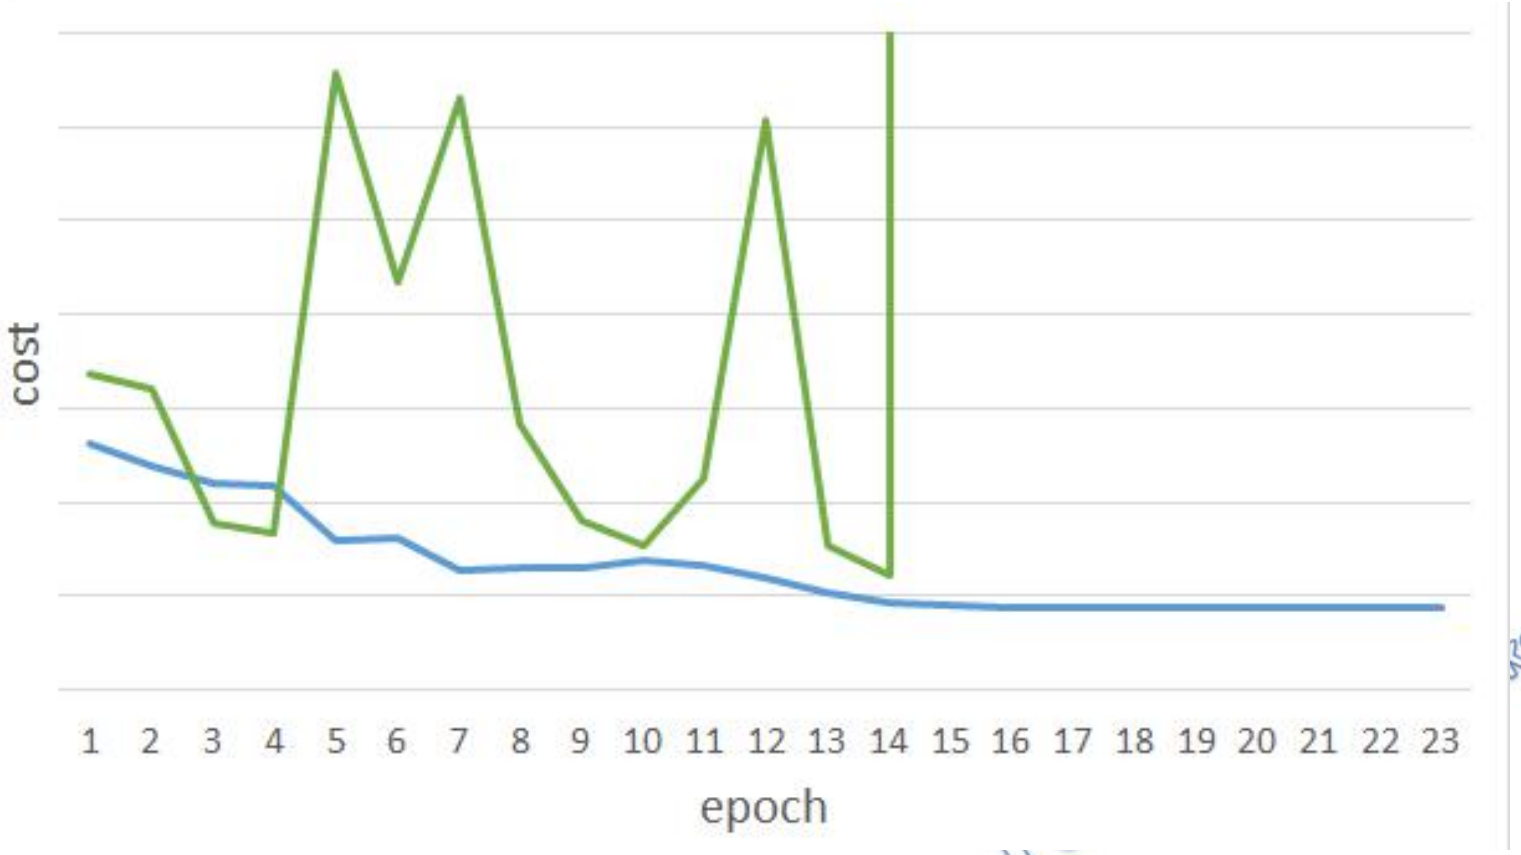

RNN与梯度消失、梯度爆炸

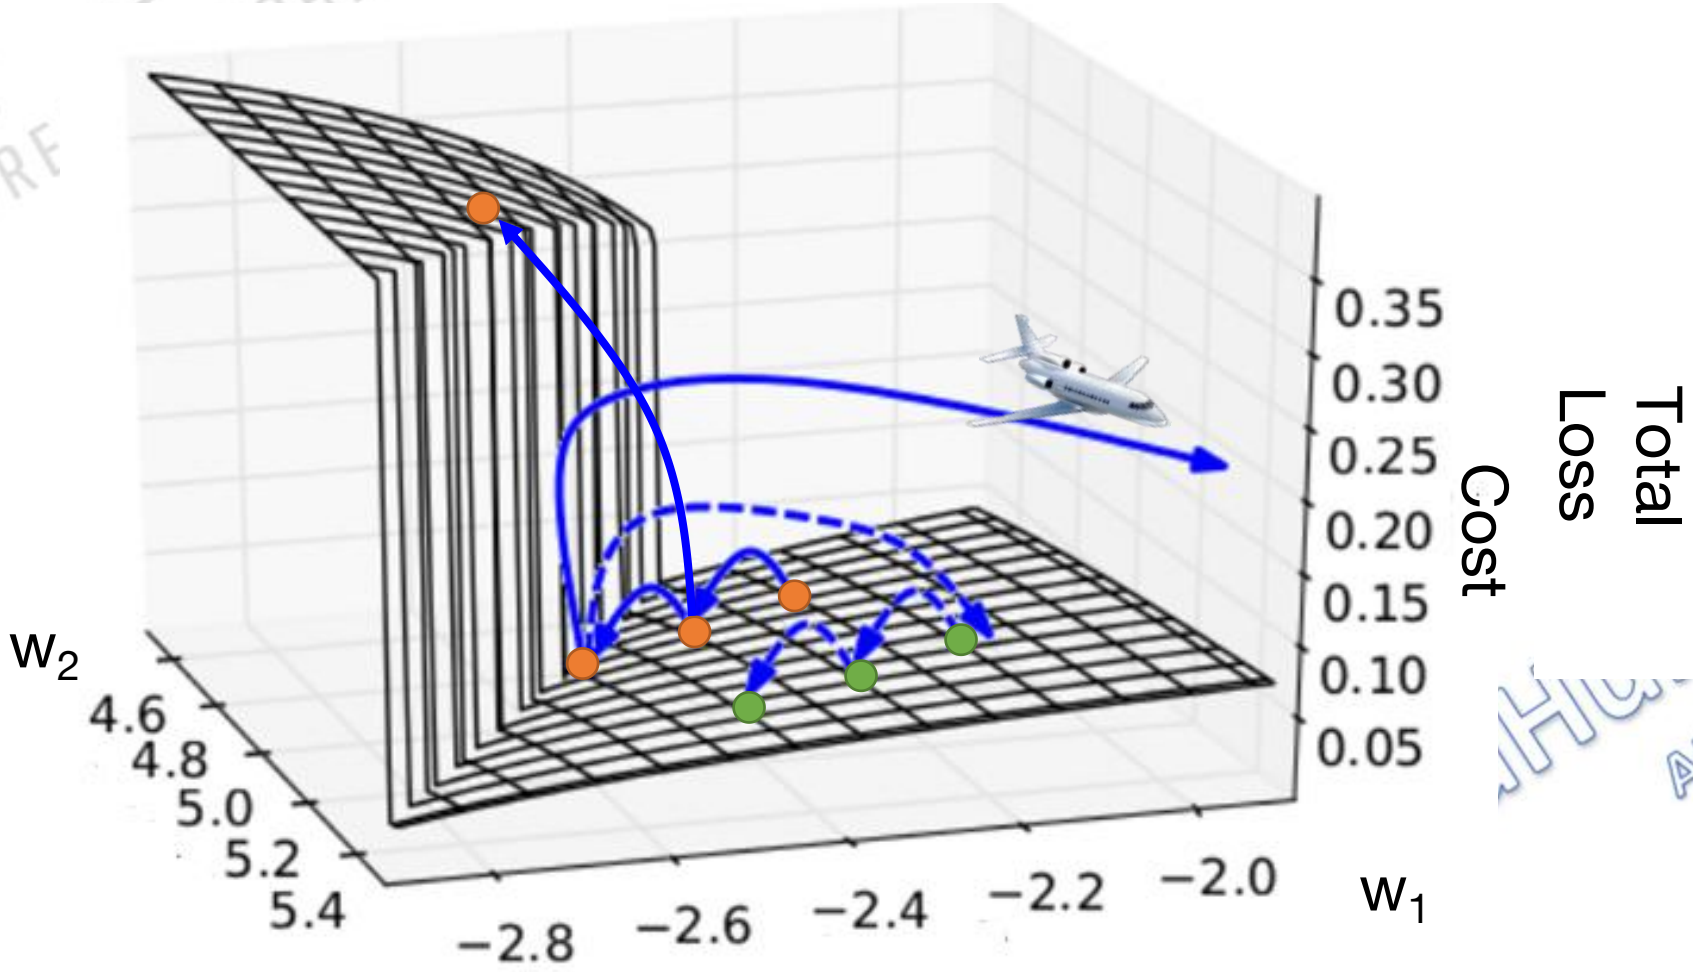

RNN与梯度消失、梯度爆炸

RNN前向传导公式为：

$$s_t = g(Ux_t + Ws_{t-1})$$
$$o_t = f(Vs_t)$$

假设t 最大为 3

损失函数为：

$$L = q(o_3, y)$$

当 t = 1：

状态：$s_1 = g(Ux_1 + Ws_0)$

输出：$o_1 = f(Vg(Ux_1 + Ws_0))$

当 t = 2：

状态：$s_2 = g(Ux_2 + Ws_1)$

输出：$o_2 = f(Vg(Ux_2 + Ws_1)) = f(Vg(Ux_2 + Wg(Ux_1 + Ws_0)))$

当 t = 3：

状态：$s_3 = g(Ux_3 + Ws_2)$

输出：$o_3 = f(Vg(Ux_3 + Wg(Ux_2 + Wg(Ux_1 + Ws_0))))$

RNN与梯度消失、梯度爆炸

当 t = 1：

状态：$s_1 = g(Ux_1 + Ws_0)$

输出：$o_1 = f(Vg(Ux_1 + Ws_0))$

当 t = 2：

状态：$s_2 = g(Ux_2 + Ws_1)$

输出：$o_2 = f(Vg(Ux_2 + Ws_1)) = f(Vg(Ux_2 + Wg(Ux_1 + Ws_0)))$

当 t = 3：

状态：$s_3 = g(Ux_3 + Ws_2)$

输出：$o_3 = f(Vg(Ux_3 + Wg(Ux_2 + Wg(Ux_1 + Ws_0))))$

$$L = q(o_3, y)$$

$$\frac{\partial L}{\partial U} = \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial U} + \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial s_2}\frac{\partial s_2}{\partial U} + \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial s_2}\frac{\partial s_2}{\partial s_1}\frac{\partial s_1}{\partial U}$$

$$= \sum_{k=1}^{3}\frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\left(\prod_{j=k+1}^{3}\frac{\partial s_j}{\partial s_{j-1}}\right)\frac{\partial s_k}{\partial U}$$

$$s_t = tanh(Ux_t + Ws_{t-1})$$

$$\prod_{j=k+1}^{3} tanh'W$$

RNN与梯度消失、梯度爆炸

$$\frac{\partial L}{\partial U} = \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial U} + \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial s_2}\frac{\partial s_2}{\partial U} + \frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\frac{\partial s_3}{\partial s_2}\frac{\partial s_2}{\partial s_1}\frac{\partial s_1}{\partial U}$$

$$= \sum_{k=1}^{3}\frac{\partial L}{\partial o_3}\frac{\partial o_3}{\partial s_3}\left(\prod_{j=k+1}^{3}\frac{\partial s_j}{\partial s_{j-1}}\right)\frac{\partial s_k}{\partial U}$$

$$s_t = tanh(Ux_t + Ws_{t-1})$$

$$\prod_{j=k+1}^{3} tanh' * W$$

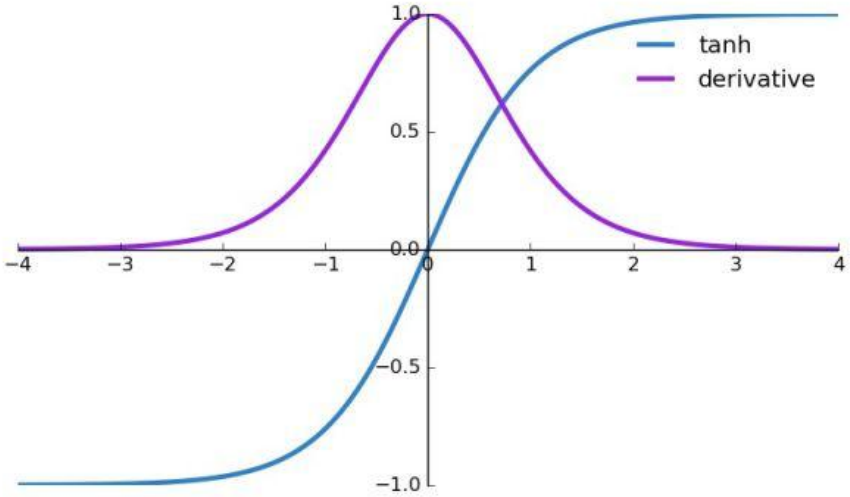

RNN与梯度消失、梯度爆炸

1、需要明确的是，RNN 中的梯度消失/梯度爆炸和普通的 MLP 或者深层 CNN 中梯度消失/梯度爆炸的含义不一样：MLP/CNN 中不同的层有不同的参数，各是各的梯度；而 RNN 中同样的权重在各个时间步共享，最终的梯度 g 等于各个时间步的梯度 g_t 的和。

2、由 1 中所述的原因，RNN 中总的梯度是不会消失的。即便梯度越传越弱，那也只是远距离的梯度消失，由于近距离的梯度不会消失，所有梯度之和并不会消失。RNN 所谓梯度消失的真正含义是，梯度被近距离梯度主导，导致模型难以学到远距离的依赖关系。

3、实践中梯度爆炸一般通过梯度裁剪来解决。

京东智联云 & 贪心科技

休息

引子：记忆机制

什么是记忆？

记忆是一种随时间而变化的状态。

引子：记忆机制

决定记忆状态的两大因素是什么？

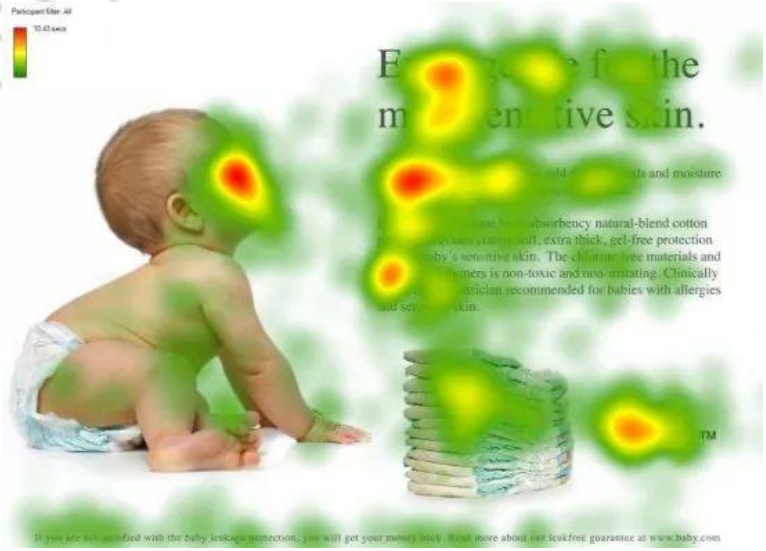

选择性的输入

选择性的遗忘

引子：记忆机制

在不同场景下的记忆输出不同。

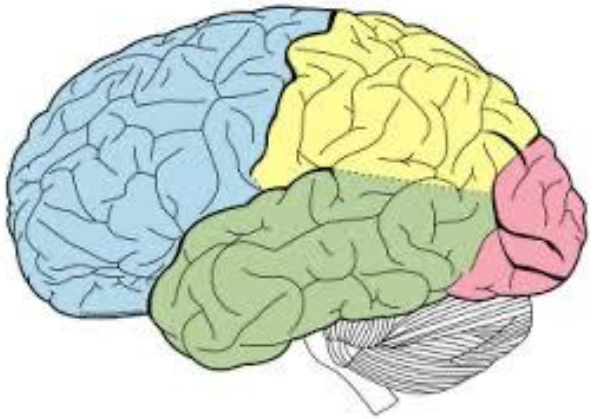

task1

task2

task3

task4

...

LSTM中的记忆机制

- 记忆是一种随时间而变化的状态。
- 决定记忆状态的两大因素：选择性的输入、选择性的遗忘。
- 在不同场景下的记忆输出不同。

LSTM中的主要概念

- 细胞状态
- 输入门
- 遗忘门
- 输出门

输入有效的信息，遗忘无用的信息，输出与任务强相关的信息应用于任务处理。

Long Short-term Memory (LSTM)

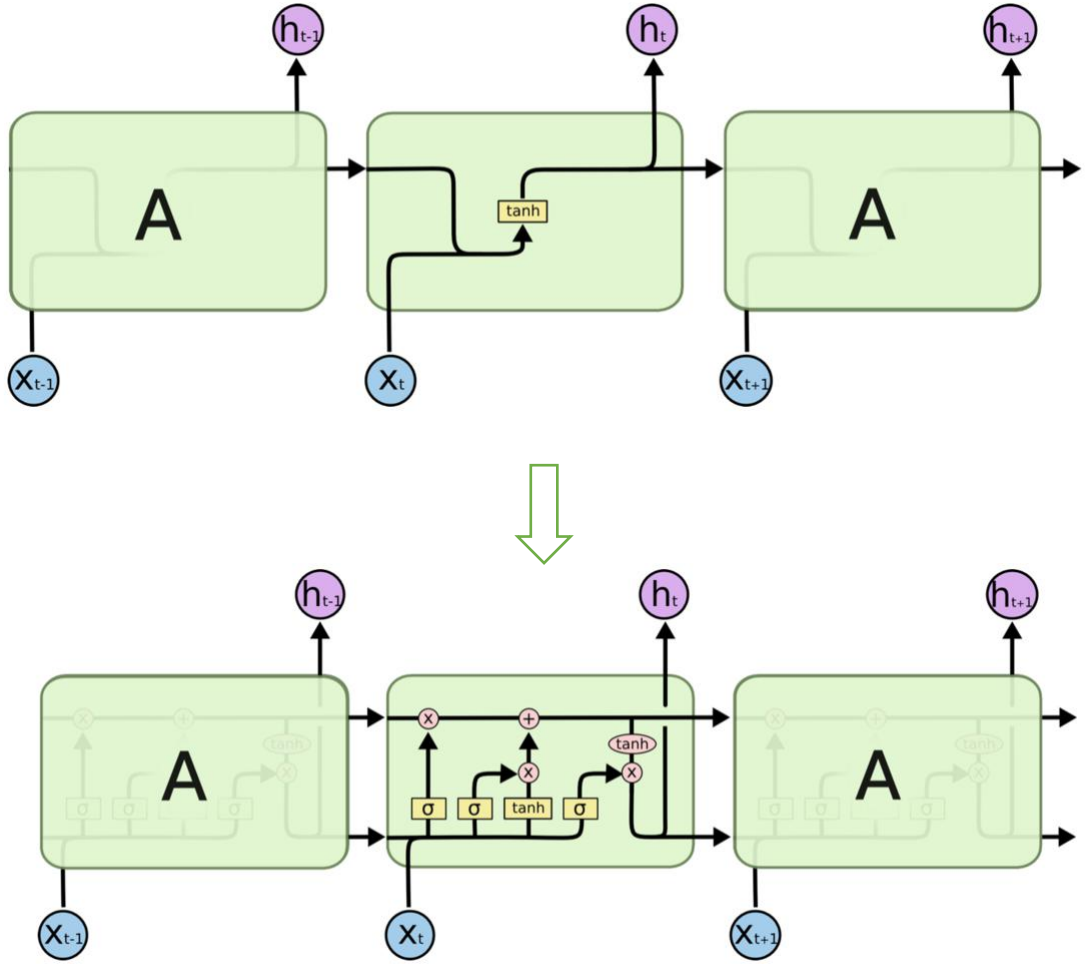

LSTM是一种特殊的RNN网络，该网络由Hochreiter & Schmidhuber (1997)引入，并有许多人对其进行了改进和普及。他们的工作被用来解决了各种各样的问题，直到目前还被广泛应用。

Long Short-term Memory (LSTM)

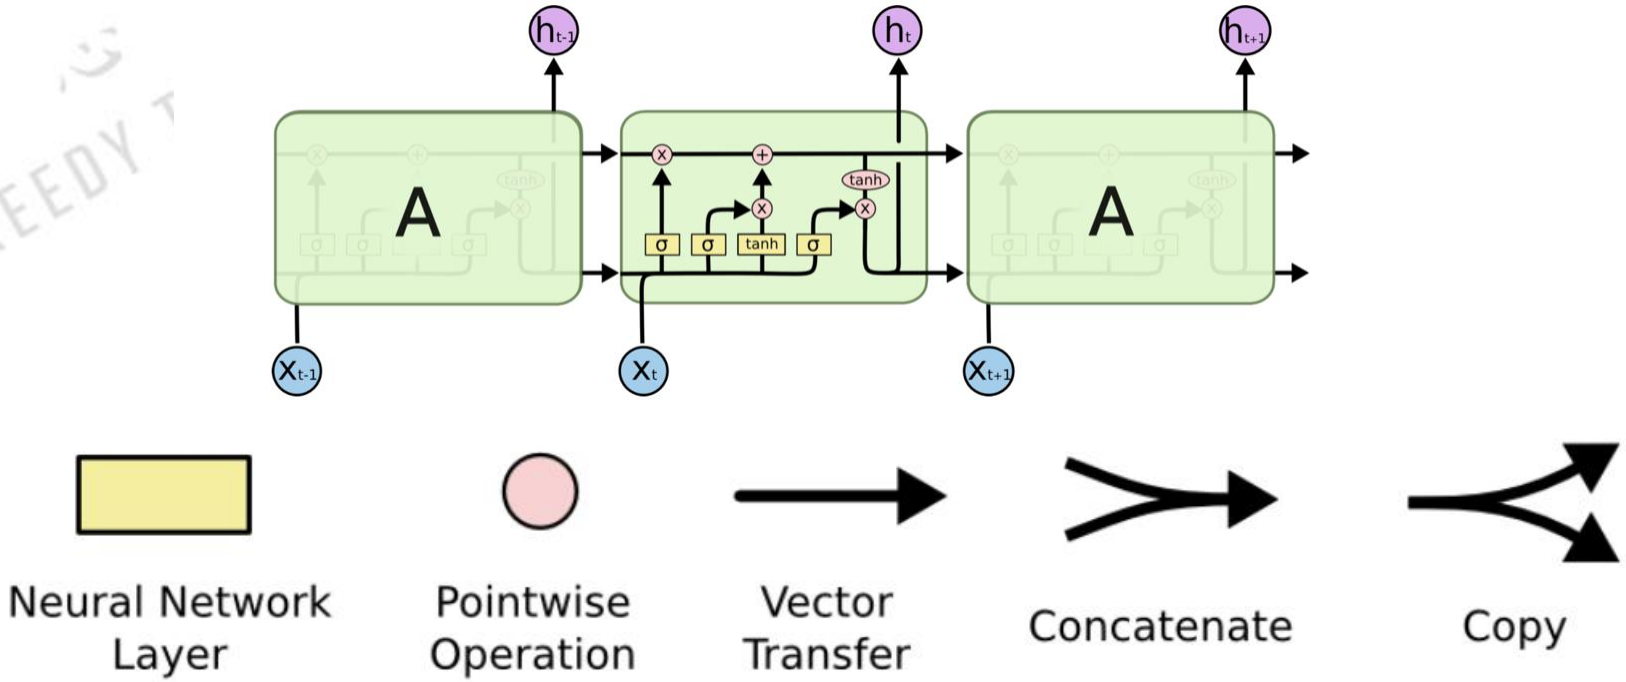

黄色方框表示激活函数操作，粉色圆圈表示点操作，单箭头表示数据流向，箭头合并表示向量的合并（concat）操作，箭头分叉表示向量的拷贝操作。

Long Short-term Memory (LSTM)

LSTMs的核心是细胞状态，用贯穿细胞的水平线表示。细胞状态像传送带一样，贯穿整个细胞却只有很少的分支，这样能保证信息不变的流过整个RNNs。（人的记忆状态贯穿人的一生。）

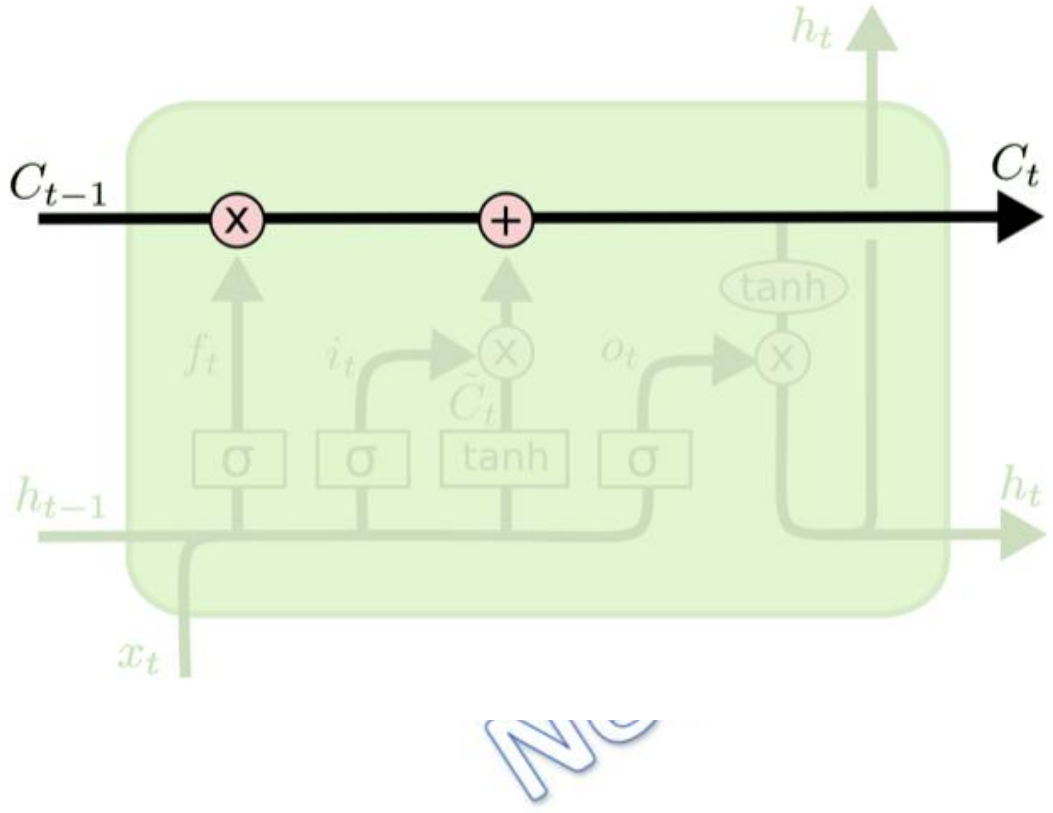

Long Short-term Memory (LSTM)

LSTM网络能通过一种被称为门的结构对细胞状态进行删除或者添加信息。

门能够有选择性地决定让哪些信息通过。其实门的结构很简单，就是一个sigmoid层和一个点乘操作的组合。
因为sigmoid层的输出是0-1的值，这代表有多少信息能够流过sigmoid层。0表示都不能通过，1表示都能通过。

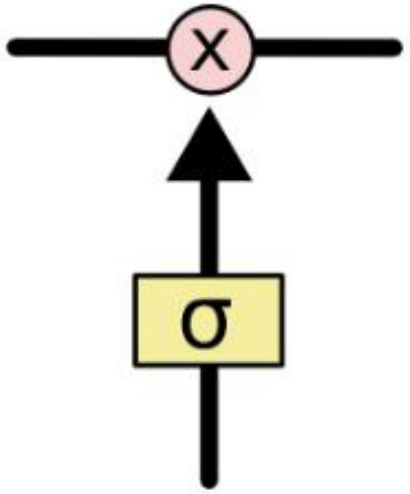

一个LSTM里面包含三个门：忘记门、输入门和输出门。

LSTM：忘记门

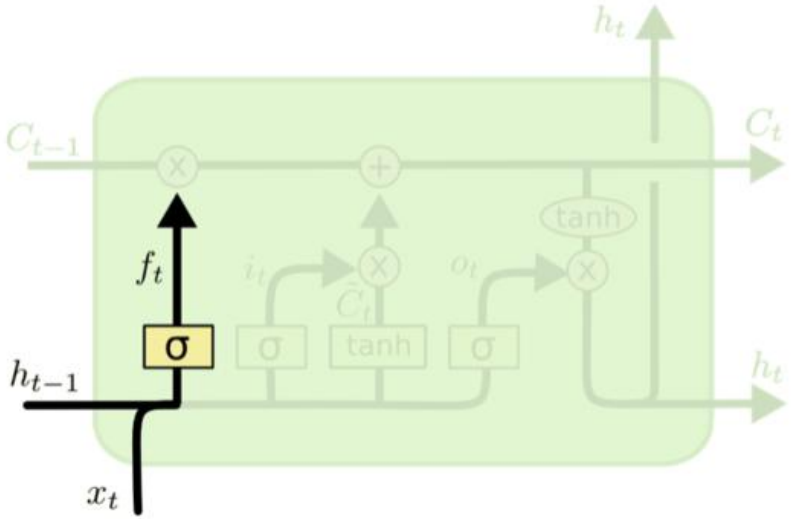

$$f^{(t)} = \sigma(W_f h^{(t-1)} + U_f x^{(t)} + b_f)$$

第一步：决定细胞状态需要丢弃哪些信息。
这部分操作是通过一个称为忘记门的sigmoid单元来处理，通过查看h_{t-1}和x_t信息来输出一个0-1之间的向量，该向量里面的0-1值表示细胞状态C_{t-1}中的哪些信息保留或丢弃多少。0表示不保留，1表示都保留。

LSTM：输入门

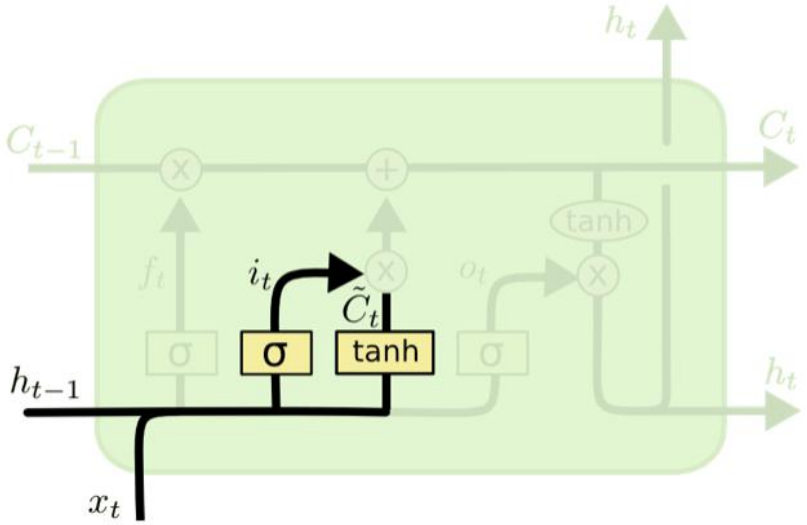

$$i^{(t)} = \sigma(W_i h^{(t-1)} + U_i x^{(t)} + b_i)$$

$$a^{(t)} = tanh(W_a h^{(t-1)} + U_a x^{(t)} + b_a)$$

第二步：决定给细胞状态添加哪些新的信息。
利用h_{t-1}和x_t通过一个称为输入门的操作来决定更新哪些信息。
再利用h_{t-1}和x_t通过一个tanh层得到新的候选细胞信息$\tilde{C}_t$（公式中的a(t)），这些信息可能会被更新到细胞信息中。

LSTM：更新细胞状态C

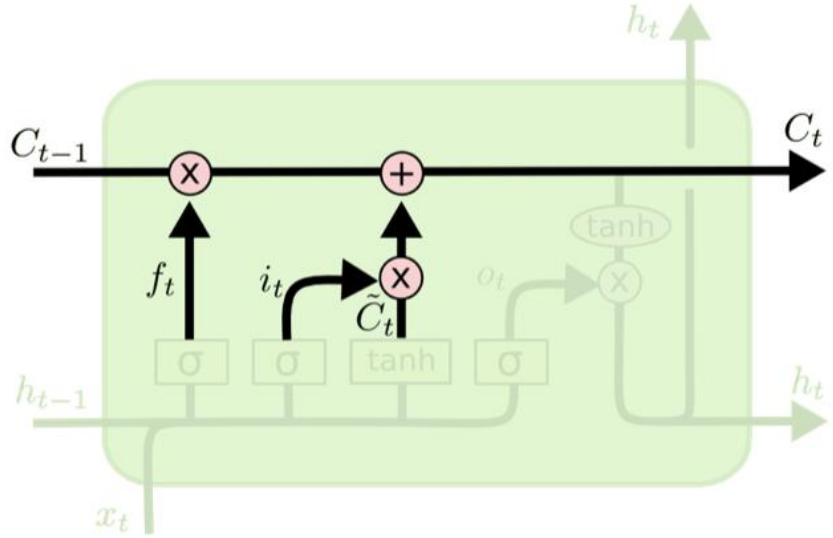

$$C^{(t)} = C^{(t-1)} \odot f^{(t)} + i^{(t)} \odot a^{(t)}$$

第三步：更新旧的细胞信息C_{t-1}，变为新的细胞信息C_t。
更新的规则，通过忘记门选择忘记旧细胞信息的一部分，通过输入门选择添加候选细胞信息$\widetilde{C_t}$(公式中的a(t))的一部分得到新的细胞信息C_t。
注：⊙为Hadamard积

LSTM：输出门

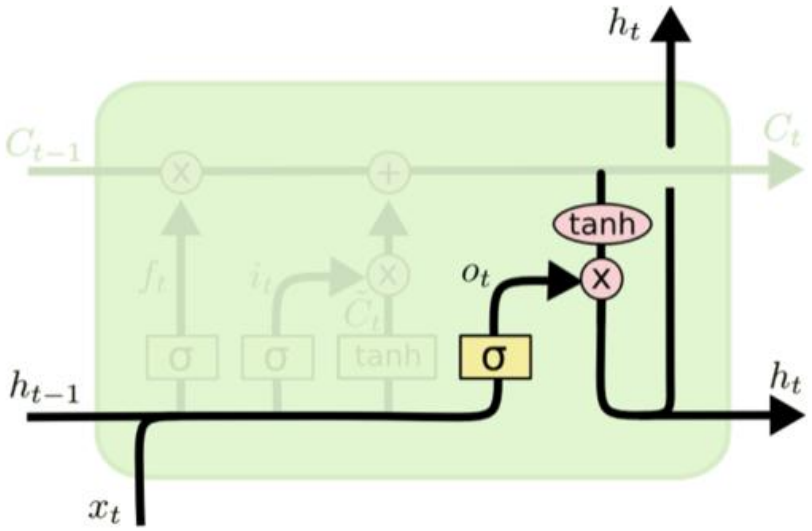

$$o^{(t)} = \sigma(W_o h^{(t-1)} + U_o x^{(t)} + b_o)$$

$$h^{(t)} = o^{(t)} \odot tanh(C^{(t)})$$

第四步：根据输入的h_{t-1}和x_t来判断输出细胞的哪些状态特征。需要将输入经过一个称为输出门的sigmoid层得到判断条件，然后将细胞状态经过tanh层得到一个-1~1之间值的向量，该向量与输出门得到的判断条件相乘就得到了最终该RNN单元的输出。

总结

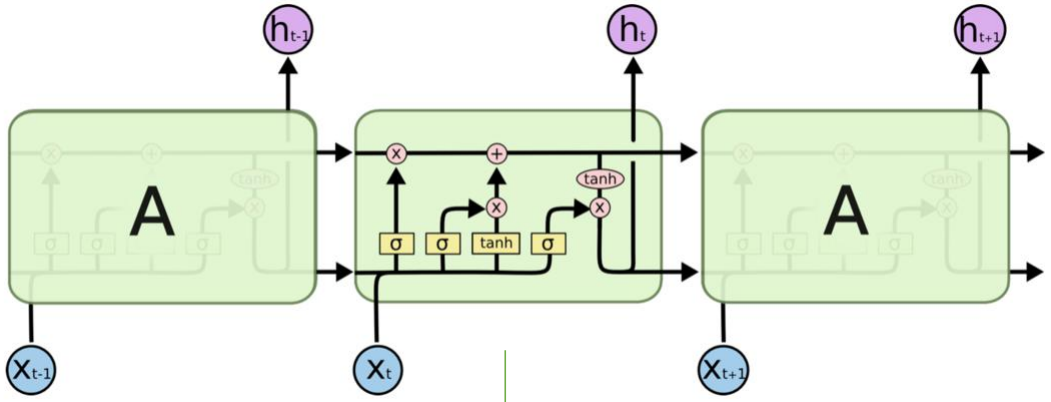

1）更新遗忘门输出：

$$f^{(t)} = \sigma(W_f h^{(t-1)} + U_f x^{(t)} + b_f)$$

2）更新输入门两部分输出：

$$i^{(t)} = \sigma(W_i h^{(t-1)} + U_i x^{(t)} + b_i)$$

$$a^{(t)} = tanh(W_a h^{(t-1)} + U_a x^{(t)} + b_a)$$

3）更新细胞状态：

$$C^{(t)} = C^{(t-1)} \odot f^{(t)} + i^{(t)} \odot a^{(t)}$$

4）更新输出门输出：

$$o^{(t)} = \sigma(W_o h^{(t-1)} + U_o x^{(t)} + b_o)$$

$$h^{(t)} = o^{(t)} \odot tanh(C^{(t)})$$

5）更新当前序列索引预测输出：

$$\hat{y}^{(t)} = \sigma(V h^{(t)} + c)$$

LSTM：视频演示

https://towardsdatascience.com/illustrated-guide-to-lstms-and-gru-s-a-step-by-step-explanation-44e9eb85bf21

start from 6:40

GRU

在GRU模型中只有两个门：

- 重置门（r）：控制前一状态有多少信息被写入到当前的候选状态 $\tilde{h}t$上的程度，重置门越小，前一状态的信息被写入的越少。
- 更新门（z）：控制前一时刻的状态信息与候选状态信息被带入到当前状态中的程度。

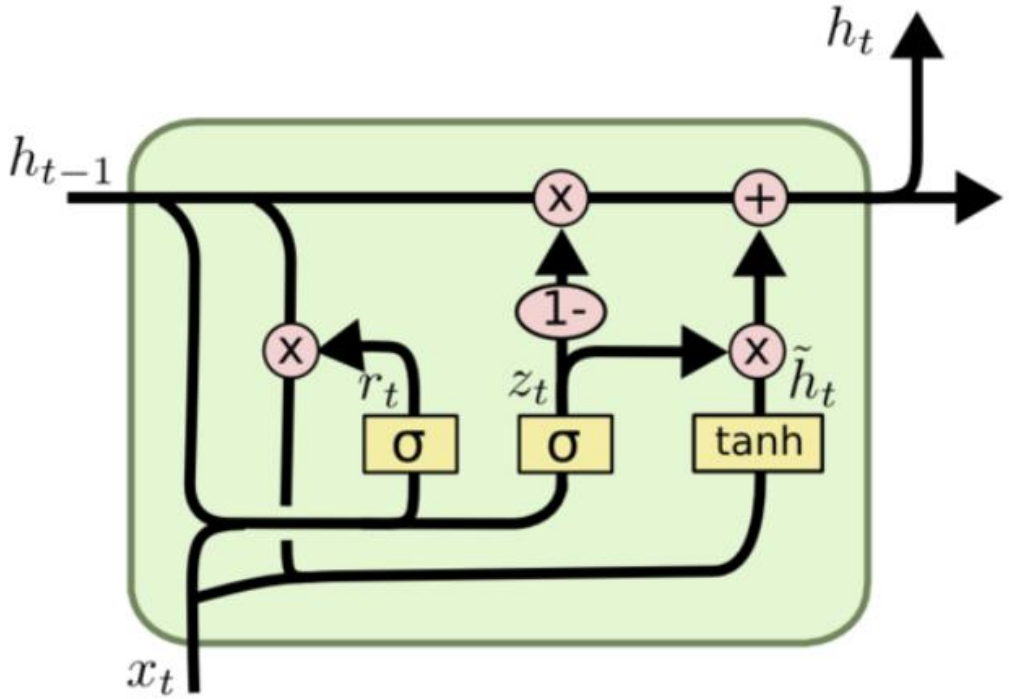

GRU

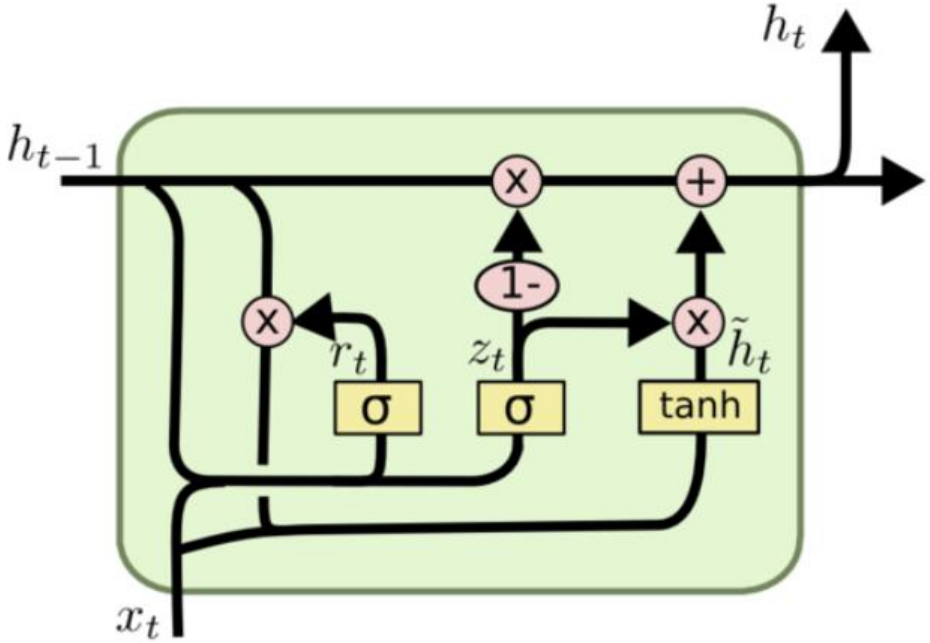

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

京东智联云 & 贪心科技

休息

LSTM代码示例

https://colab.research.google.com/drive/1Zfvt9Vfs3PrJwSDF8jMvomz7CzU36RXk

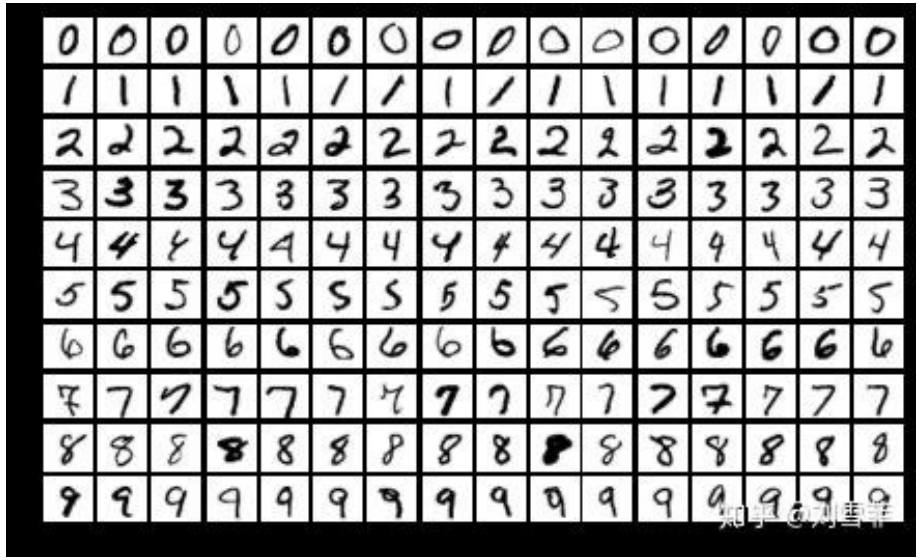

LSTM代码示例

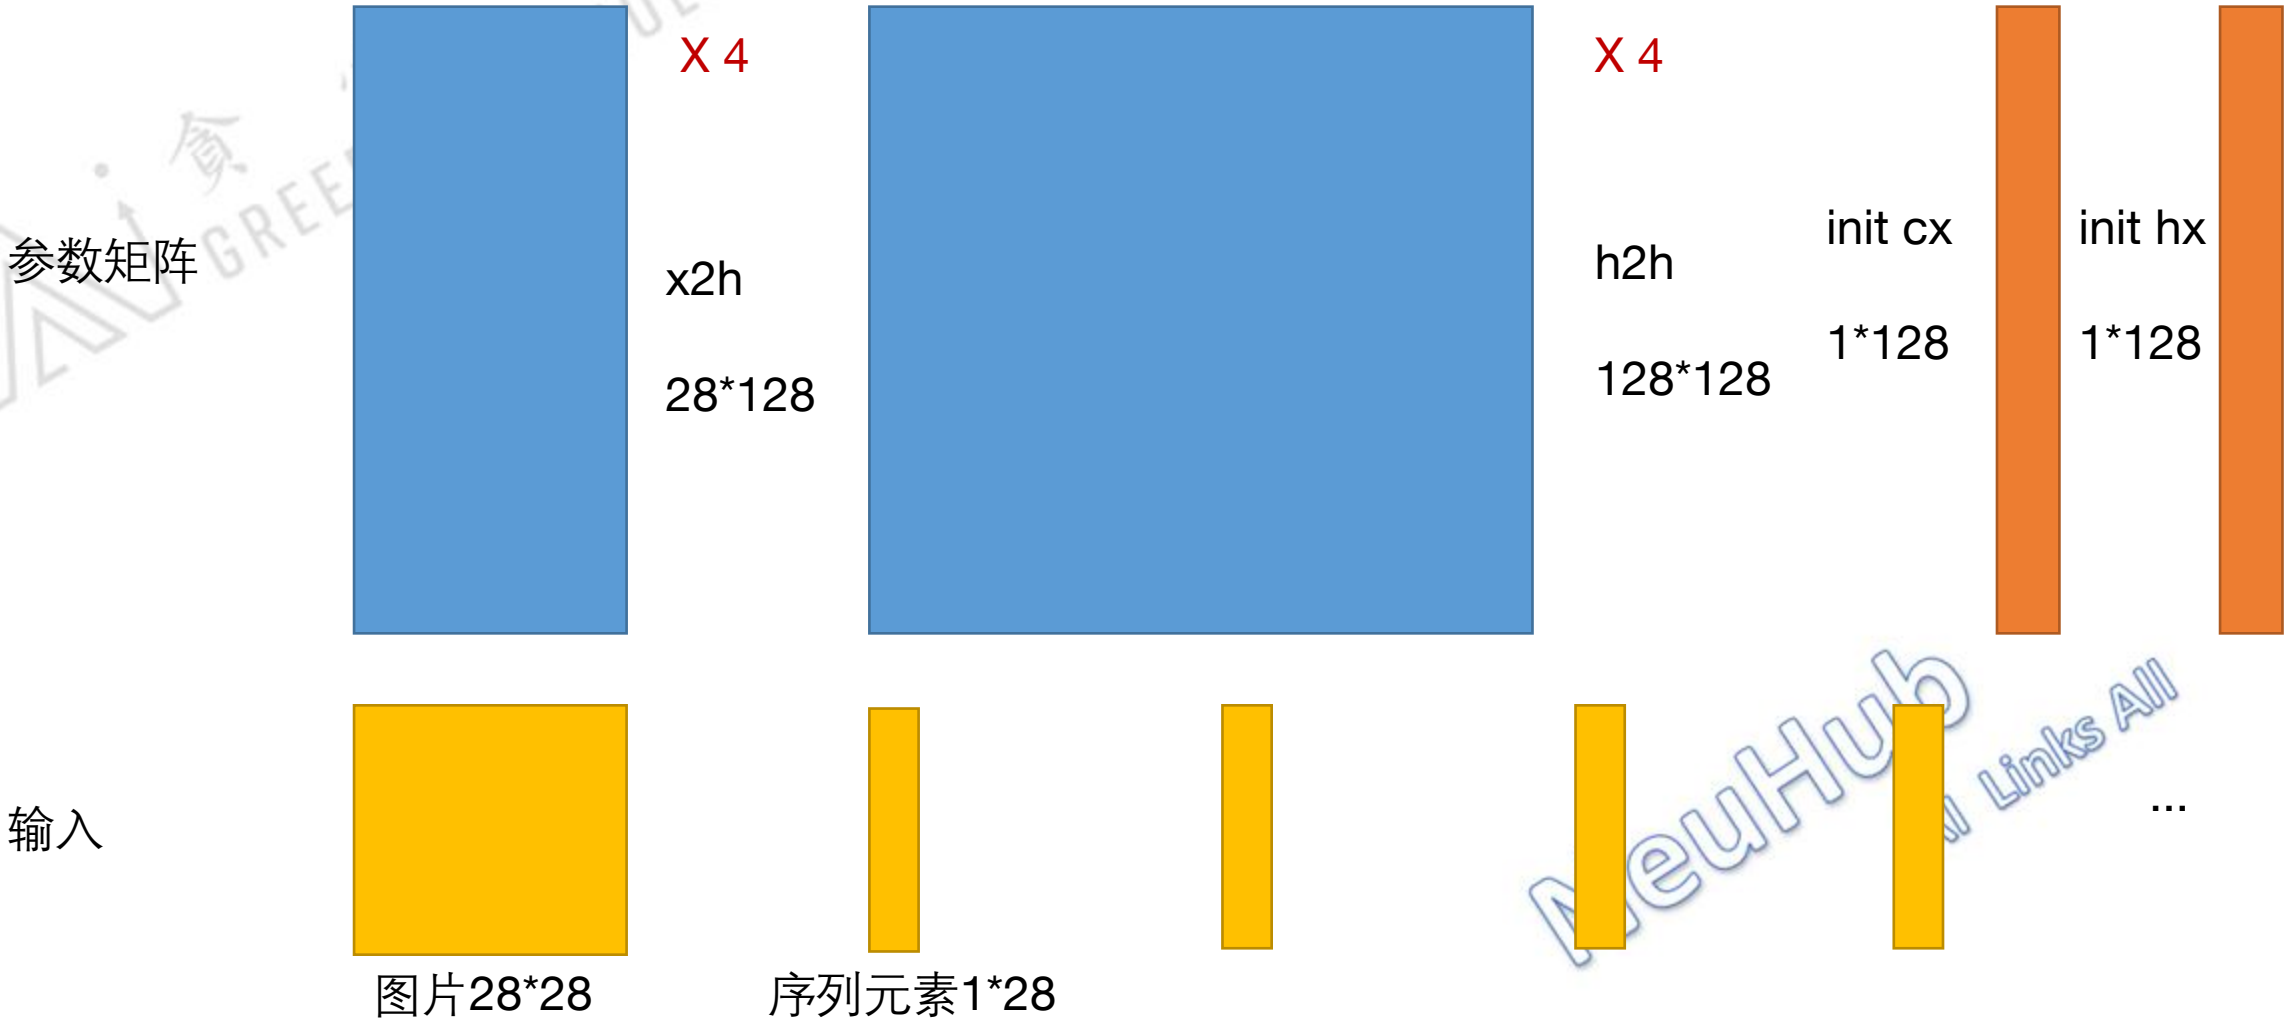

LSTM代码示例

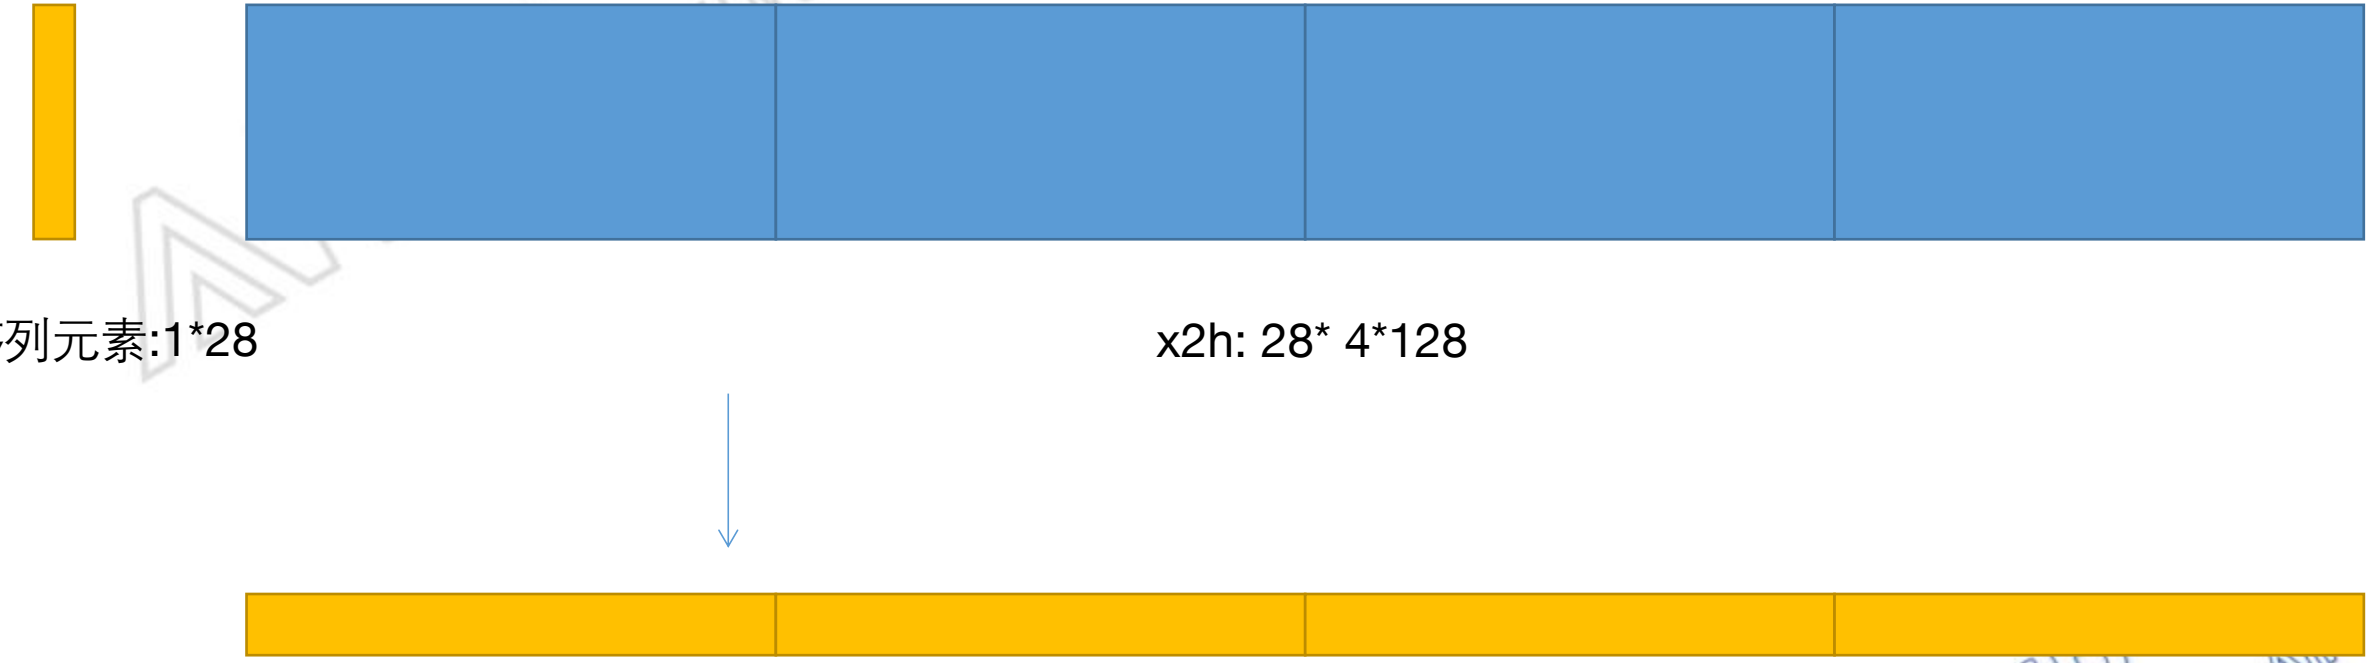

LSTM代码示例

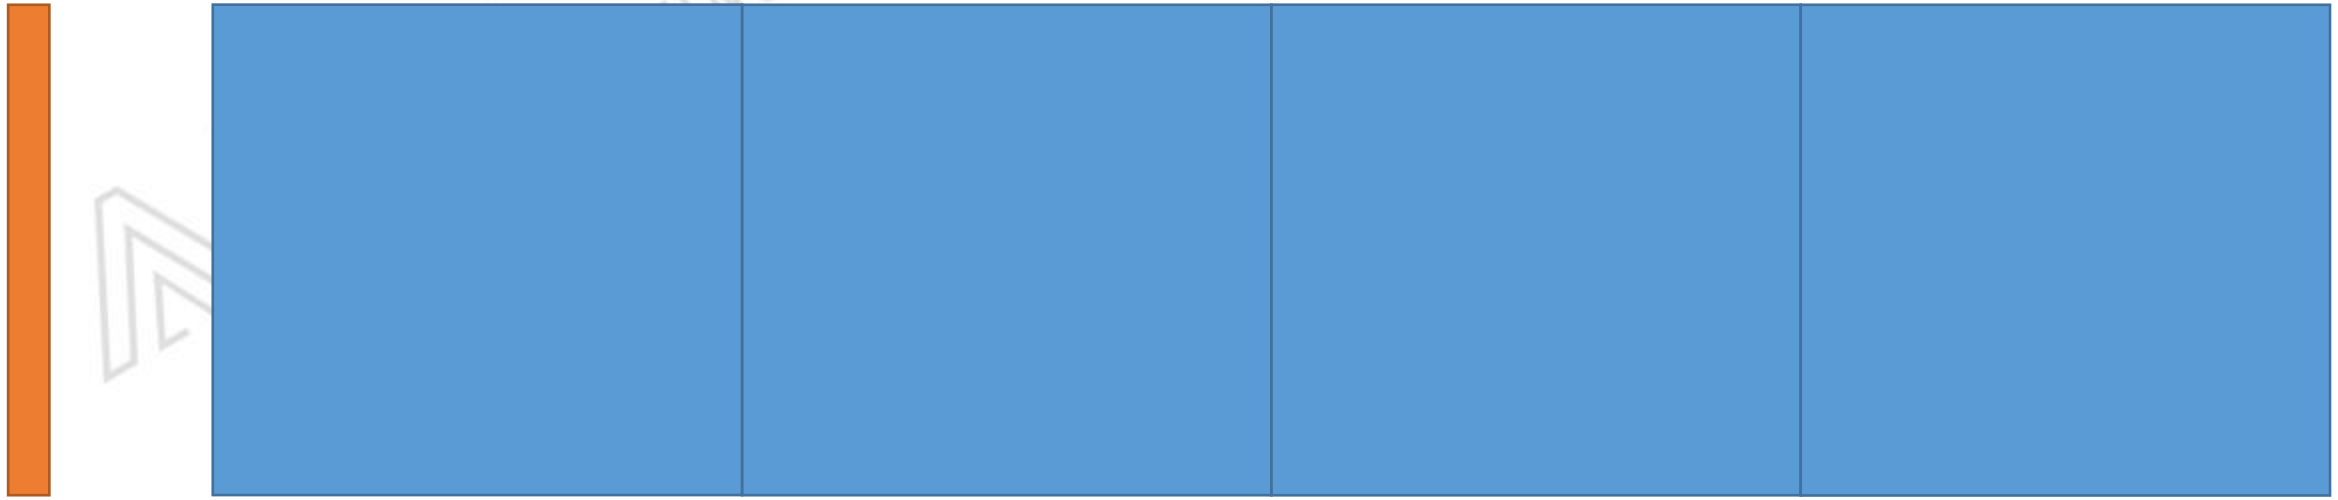

hx:1*128

h2h: 128* 4*128

1* 4*128

LSTM代码示例

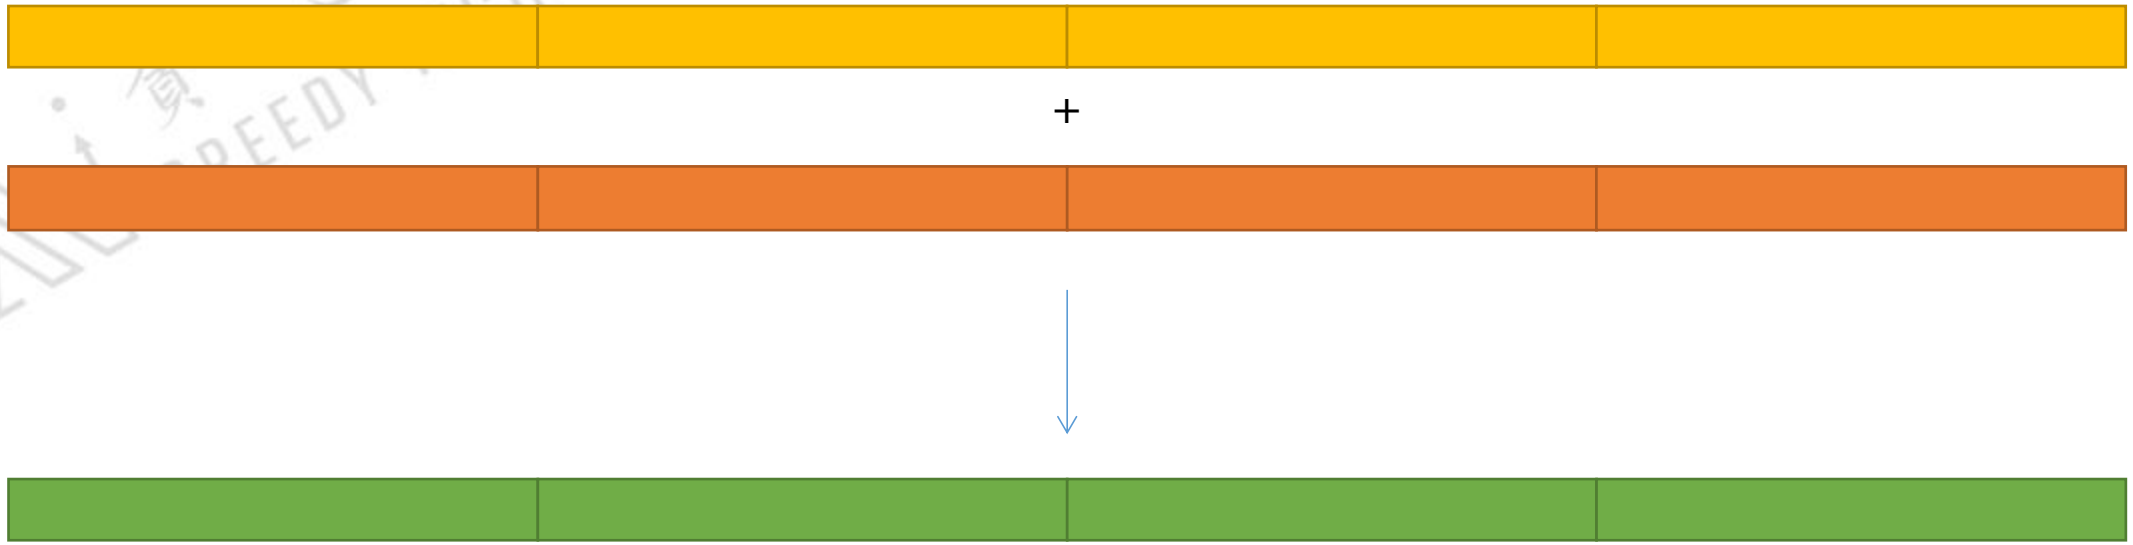

LSTM代码示例

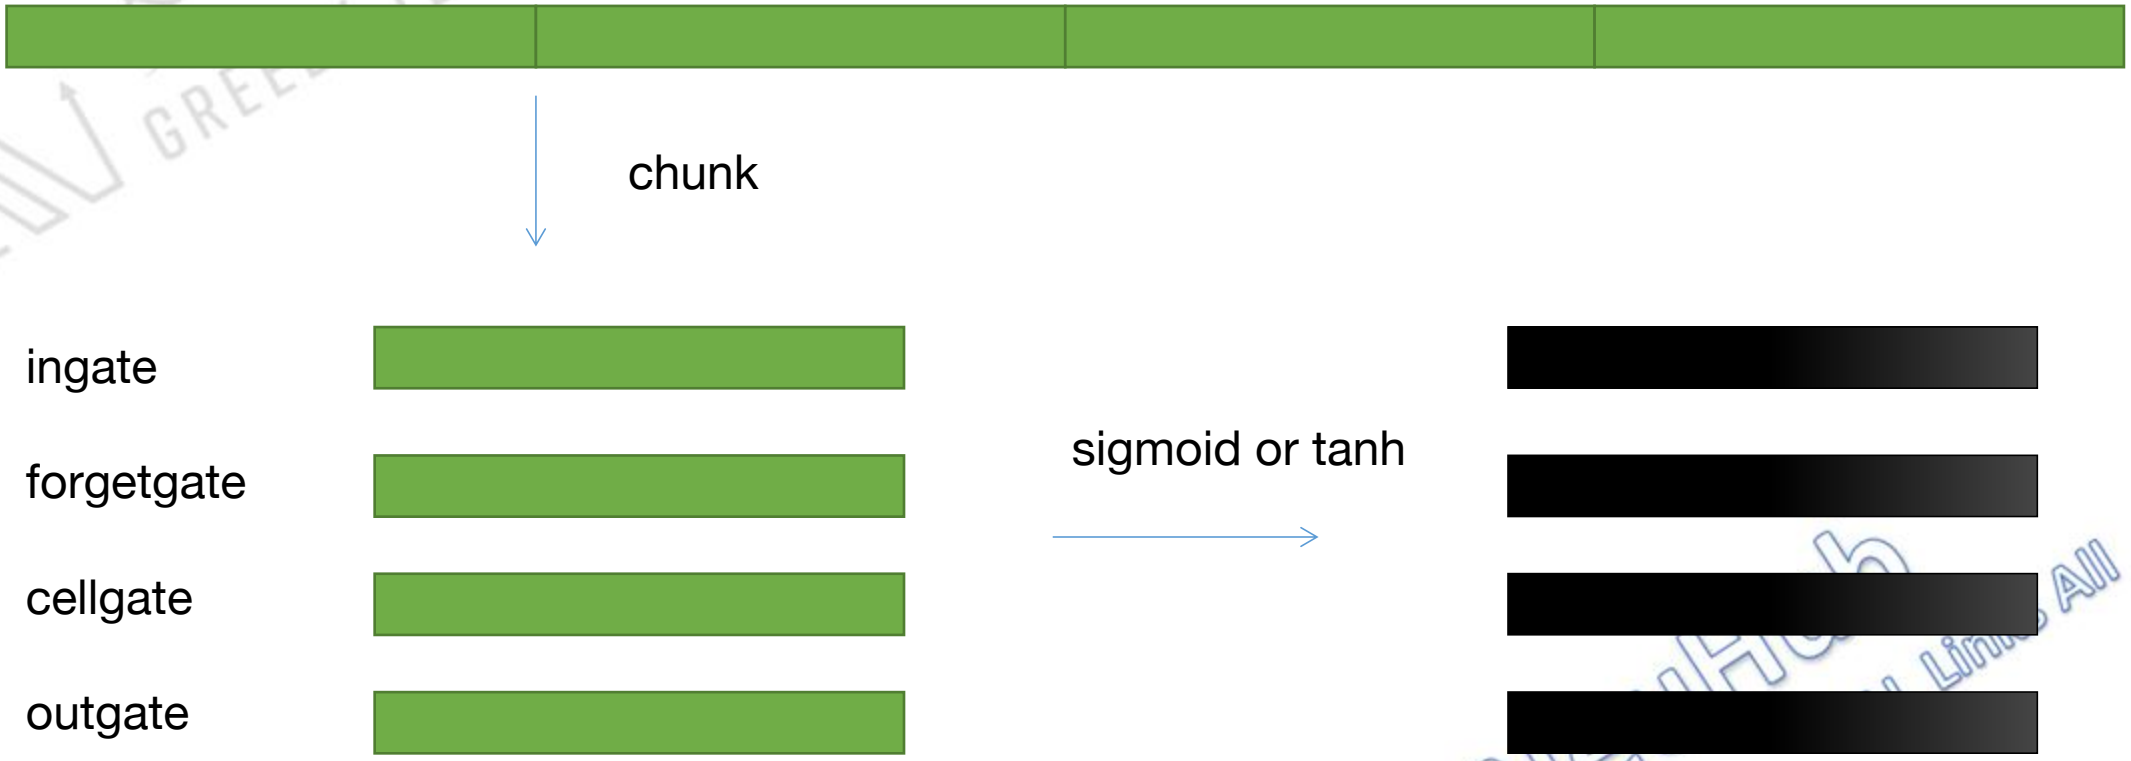

LSTM代码示例

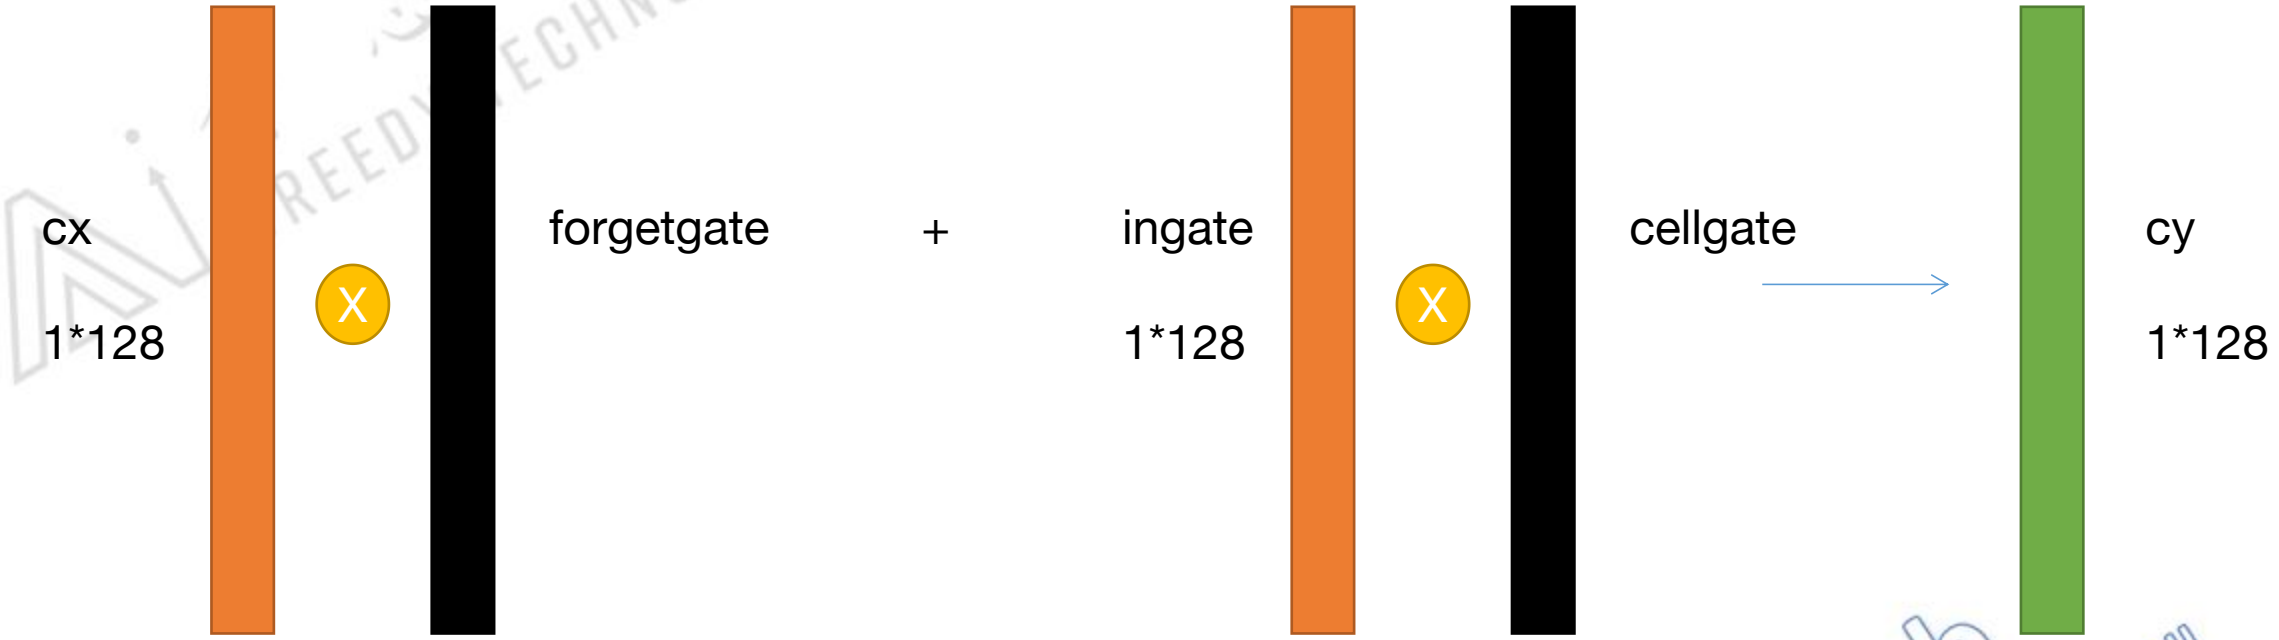

LSTM代码示例

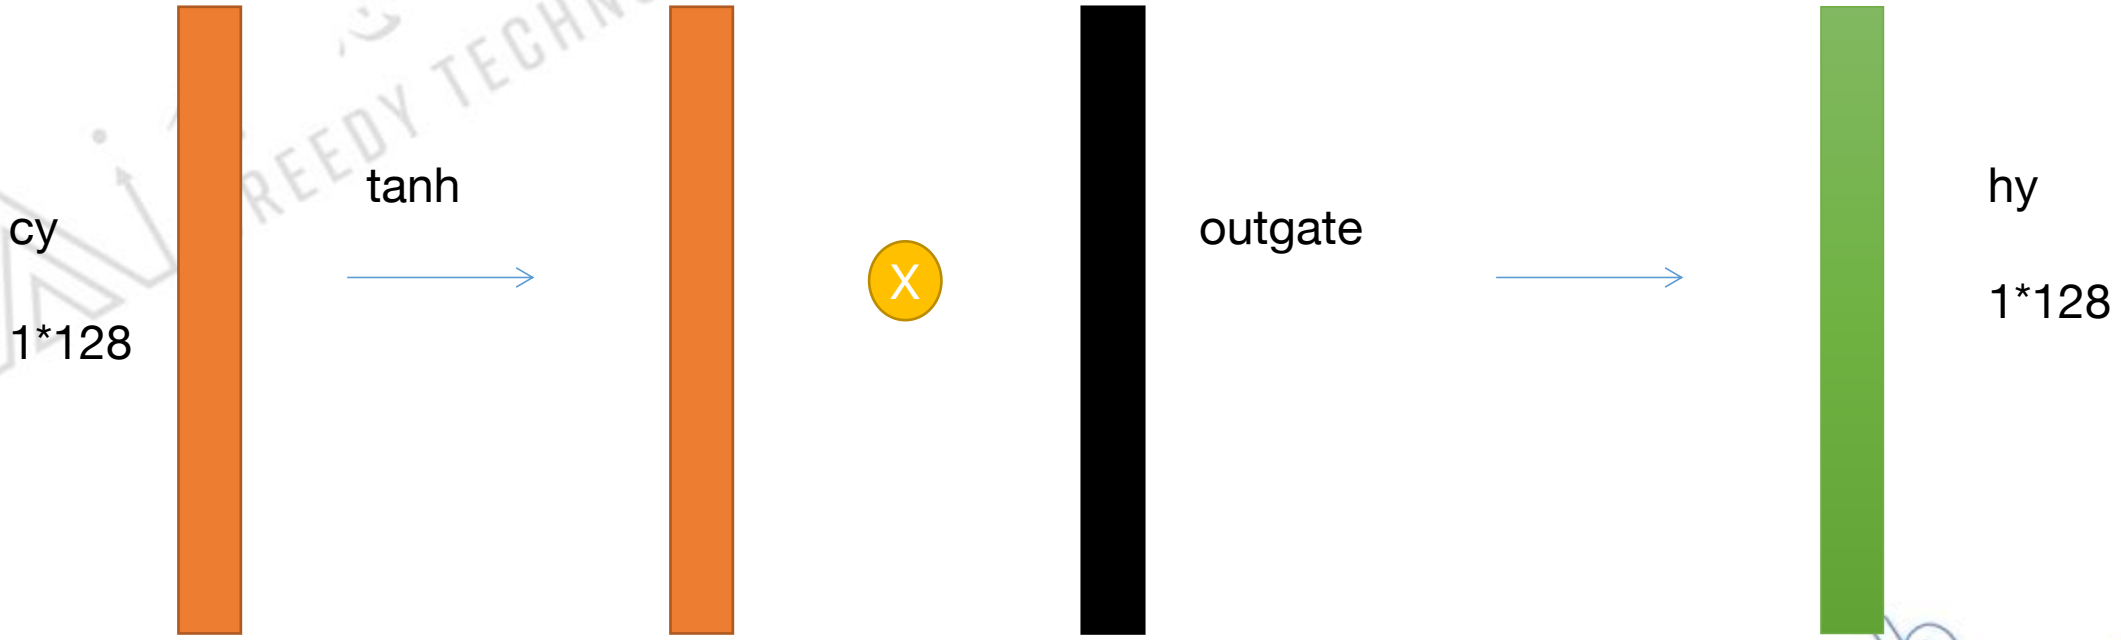

LSTM代码示例

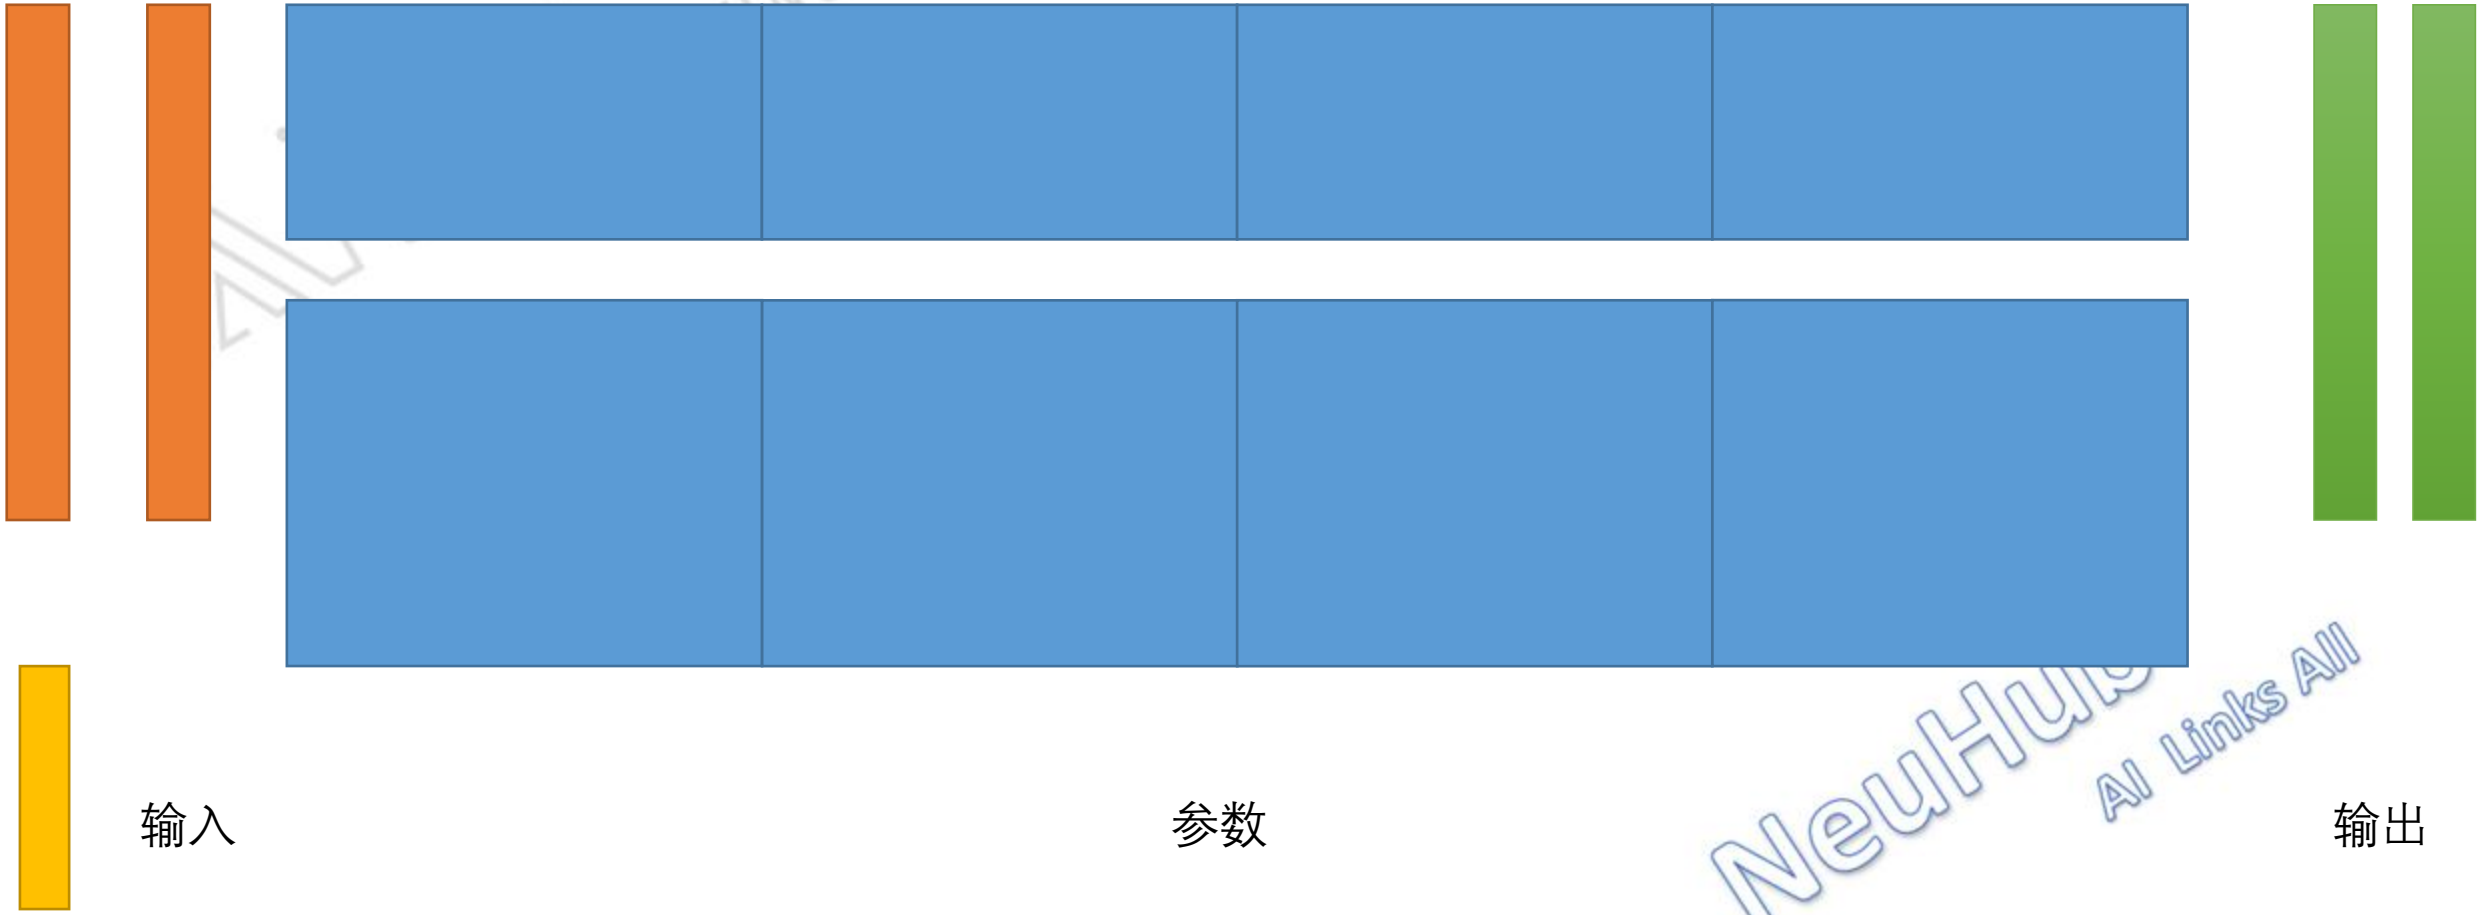

典型面试题

京东智联云 & AI

- RNN在训练过程中存在什么问题？如何解决？
- LSTM与RNN相比，有哪些特点？
- 请画出LSTM的基本结构。
- 循环神经网络可以解决哪些问题？

作业

京东智联云 & 贪心科技

- https://medium.com/datadriveninvestor/how-do-lstm-networks-solve-the-problem-of-vanishing-gradients-a6784971a577
- 参考以上文章写一篇blog
- 主题：为什么LSTM可以解决RNN梯度消失的问题

参考

RNN

- https://zybuluo.com/hanbingtao/note/541458

LSTM

- http://colah.github.io/posts/2015-08-Understanding-LSTMs/
- https://www.youtube.com/watch?v=9zhrxE5PQgY&feature=youtu.be
- https://towardsdatascience.com/illustrated-guide-to-lstms-and-gru-s-a-step-by-step-explanation-44e9eb85bf21
- https://medium.com/datadriveninvestor/how-do-lstm-networks-solve-the-problem-of-vanishing-gradients-a6784971a577